视觉-文本大模型 + 机器学习 / 卷积网络 八股问答

> 与《八股知识问答 118 问》的分工：那份是**多模态总览 + 项目接口话术**，这份是**VLM 深度知识 + 机器学习算法原理推导**，两份不重复、可对照看。 编号用 A（视觉-文本大模型，45 问）、B（机器学习算法，45 问）、C（图像处理与卷积网络 + 视觉基础模型，68 问），共 **158 问**，避免与 Q1~Q118 冲突。 **§ B6 附原理验算代码**（47 项断言，面向 Python 语法不熟者逐行注释）。 难度：★★★ 几乎必问 · ★★ 大概率问 · ★ 加分题。

Part A 视觉-文本大模型（VLM）

A1 模型族谱与架构（A1–A12）

A1 ★★★ VLM 有哪几种架构范式？各自的代表模型和取舍？

A：四种范式，按"视觉怎么进语言模型"分：

范式	结构	代表	取舍
① 双塔对比（encoder-only）	图像塔 + 文本塔，各自编码后算相似度	CLIP、ALIGN、SigLIP	检索/零样本分类强，**不能生成**，只学全局对齐
② 融合编码器	图文进同一个 Transformer（cross-attention 交互），输出融合表征	ALBEF、BLIP、ViLT	适合匹配/理解类任务，参数量比双塔小，但仍不生成自由文本
③ 编码器-解码器桥接（主流 VLM）	冻结/半冻结视觉塔 → 桥接层 → LLM 自回归生成	BLIP-2、LLaVA、Flamingo、Qwen-VL、InternVL	**能力最强、可指令化**，代价是 token 多、训练分阶段
④ 原生/早期融合（Early fusion）	一开始就把图像 patch 与文本 token 拼进同一个序列，统一自回归	Chameleon、Emu3、Fuyu	结构最简洁、天然支持交错图文，但需从零训或大改，工程门槛高

面试答法："主流是第 ③ 种——因为它的训练成本最低（可冻结双塔）、能力上限又最高；第 ④ 种是方向但需要从头训，数据门槛太高。"

追问：Fuyu 有什么特别？→ **没有独立视觉编码器**，直接把图像 patch 线性投影成 token 送进语言模型，省掉视觉塔、也省掉桥接层，代价是需要更强数据、分辨率灵活性靠 patch 切分。

A2 ★★★ LLaVA、BLIP-2、Flamingo 三者的桥接设计有什么本质区别？

A：

	桥接方式	视觉 token 数量	训练成本	核心思想
LLaVA	2 层 MLP（线性投影）	**不压缩**（与 patch 数相同）	最低（只训 MLP）	视觉塔特征已够好，简单映射即可
BLIP-2	**Q-Former**（32/64 个可学习 query + cross-attention）	**固定**（32/64）	中（两阶段多任务）	压缩 + 强对齐
Flamingo	Perceiver Resampler + **LLM 里插 gated cross-attention**	固定（resampler 输出）	中（插入新层）	不改 LLM 主干权重，只加"旁路"

本质区别一句话：LLaVA 是"**改维度**"，BLIP-2 是"**压数量 + 强对齐**"，Flamingo 是"**在 LLM 内部做融合**"。

追问：为什么 LLaVA 敢用最笨的 MLP？→ 因为它冻结双塔、数据量大（数十万~百万级指令），MLP 已经足够；而且论文消融显示，在冻结设定下复杂桥接的收益不显著。**这是"简单方案 + 足够数据"胜过"精巧结构"的典型案例。**

A3 ★★★ 视觉塔为什么大多用 CLIP/SigLIP 而不是 ImageNet 预训练的 ResNet/ViT?

A：三条理由：

1. **语义空间已经和文本对齐**：CLIP 系在 4 亿级图文对上做过对比学习，特征里已经含"可被语言描述"的语义；ImageNet 特征是判别 1000 类的，语义粒度不匹配。
2. **冻结就能用**：CLIP 特征在冻结条件下零样本泛化好，适合 VLM"冻结视觉塔"的训练范式。
3. **ViT 结构同构**：patch token 序列可以直接送进 LLM，不需要额外适配。

什么时候不用 CLIP：需要**密集预测**（分割/深度/占用）时，CLIP 的全局对齐特征反而丢失细粒度空间信息，这时 DINOv2（自蒸馏，保留空间结构）或纯监督 ViT 更合适。**混合做法**：CLIP 塔给语义 + DINOv2 给结构，双塔拼接。

追问：SigLIP 比 CLIP 好在哪？→ 用 pairwise sigmoid 替代 softmax 交叉熵，**不需要全 batch 归一化**，因此 batch 可以小、能分布式异步训练，更省内存；效果同级甚至更好，是现在很多开源 VLM 的默认视觉塔。

A4 ★★ BLIP 的 CapFilt 是干什么的?

A：网页图文对（alt-text）噪声大——图里是"一只狗在草地上"，alt-text 却是"点击购买"。CapFilt = **Captioner + Filter**：

1. **Captioner**：用图像生成 caption（合成描述）；
2. **Filter**：用 ITM 头判断"图文是否匹配"，把原 alt-text 和合成 caption 里不匹配的过滤掉。

本质是用模型给自己造更干净的监督（bootstrapping）。这条和现在"用强 VLM 重新 caption 训练数据"（ShareGPT4V 一类）是同一思想。

A5 ★★ ALBEF 的三个训练目标是什么？为什么需要 ITM?

A：**ITC（图文对比）+ ITM（图文匹配）+ MLM（掩码语言建模）**。

- **ITC** 学全局粗对齐（快、但只能到"整体像不像"）；
- **ITM** 用融合后的特征做二分类（细粒度、但要负样本，靠 ITC 的相似度做 **hard negative 挖掘**）；
- **MLM** 让模型学词级与图像区域的对应（补细粒度）。

为什么需要 ITM：ITC 用的是各自独立的编码（没有跨模态交互），学不到"这个词对应这块区域"；ITM 让图文进同一个编码器交互。**代价是推理时每对都要过一次融合编码器，慢——所以 BLIP-2 之后就用生成式目标替代了它。**

A6 ★★ CoCa 和 BLIP 的思路差异?

A：CoCa 把"**对比学习**（对齐）"和"**caption 生成**（生成）"放在**一个模型的两个头**上，共享图像编码器：一个头做图文对比（学判别式表征），另一个头做自回归 caption（学生成能力）。

意义：**证明对齐与生成可以共存且互补**（对比目标提供稳定的语义空间，生成目标提供细粒度语言监督）。现在很多 VLM 训练都是这个混合思路的延伸。

A7 ★★★ 视觉 token 到底有多少？为什么它是 VLM 的"预算中枢"?

A：算一遍就有体感： - 336×336、patch14 → 24×24 = **576 token** - 448×448、patch14 → 32×32 = **1024 token** - LLaVA-1.6 的 anyres（4 切片 + 1 缩略图）→ 约 **2880 token** - InternVL 的 pixel shuffle（2×2 拼通道）→ token **÷4**

而一张 4096 上下文的 LLM，一张高分辨率图就能吃掉 70%。所以：**分辨率（看得清）↔ token 数（算力/显存）↔ 上下文（能塞几张图/多轮）三者是硬约束的三角**。

工程手段：pixel shuffle、池化、Q-Former 压缩、动态分辨率（按需给 token）、只取关键帧（视频）。

A8 ★★ Qwen-VL 的 M-RoPE 解决什么问题?

A：普通 RoPE 是 1D 的（按序列位置旋转），但视觉 token 有 **时间（帧）+ 高 + 宽** 三维结构。M-RoPE（Multimodal RoPE）把旋转维度切成三份，分别编码 t/h/w，于是： - 同一帧内相邻 patch 的相对位置正确； - 不同帧之间有时间相对关系； - 图像与文本混排时位置语义不乱。

意义：让一个模型同时处理**图像、多图、视频**而不需要改结构——这是"原生多模态位置编码"的代表做法。

A9 ★ InternVL 的 pixel shuffle 为什么能省 token?

A：把相邻 2×2 个 patch 在**通道维**拼起来：原本 4 个 patch 各 `d` 维 → 合成 1 个 patch `4d` 维。token 数 ÷4，再用一个 MLP 把 `4d` 投回 `d`。

代价：空间分辨率信息被"压缩进通道"，细粒度定位会略损；但配合**动态分辨率**（大图切块）能补回来。这是"用通道换序列长度"的典型取舍。

A10 ★★ MiniGPT-4 和 LLaVA 的差别是什么?

A：结构上 MiniGPT-4 用 **Q-Former + 单层线性投影**（沿用 BLIP-2 的视觉侧），LLaVA 用 **CLIP ViT + 2 层 MLP**。数据上 MiniGPT-4 用短 caption 预训练 + 高质量长对话微调（用 GPT-4 生成、人工清洗），LLaVA 用 GPT-4 生成的视觉指令数据。

历史意义：MiniGPT-4 证明了"冻结 LLM + 轻量桥接"能获得对话式视觉能力；LLaVA 把这条路线做到了极致简化 + 规模化，成为开源 VLM 的事实标准。

A11 ★ 原生多模态（Early fusion）和"桥接式"到底差在哪?

A：差在**融合发生的位置**和**训练方式**：

- 桥接式：视觉塔独立编码（可能冻结）→ 投影 → 拼进 LLM 序列。融合发生在 LLM 的第一层之后（视觉 token 已经是"外来词"）。
- 原生式：图像 patch 直接当 token，与文本 token 从第一层起就在同一序列里做 attention。**模型从一开始就不知道"这是图像"还是"这是文本"**，全靠数据学。

代价：原生式通常要从头预训练（或大规模继续预训练），数据门槛极高；好处是**交错图文（多图穿插在长文档里）**天然支持，且不会出现"视觉塔与 LLM 表征错配"。

A12 ★ 视觉塔参数量要不要大？为什么很多模型用 ViT-L 而不是 ViT-H/G?

A：这是**性价比**问题。视觉塔只在 prefill 时跑一次，但它的计算量与**分辨率平方 × 参数量**挂钩；而 LLM 的算力主要在 decode（逐 token）。所以在"视觉塔够用"的前提下，加参数到视觉塔的边际收益远低于加在 LLM 上。

实践：ViT-L（约 300M）是主流；追求更强视觉理解时才上 ViT-H/SoViT；端侧反过来会用 ViT-S/B 配蒸馏。

A2 训练范式与数据（A13–A22）

A13 ★★★ VLM 训练为什么必须分阶段？一次性端到端训行不行?

A：能训，但**代价大且不稳**，原因三条：

1. **初始化错配**：随机初始化的桥接层输出是噪声，若同时解冻 LLM，这些噪声会通过梯度污染 LLM 的预训练能力（灾难性遗忘）。
2. **学习率不可共享**：视觉塔需要小 lr（保护预训练特征），桥接层需要大 lr（从零学），LLM 需要中 lr。分阶段可以分别设。
3. **数据配比不同**：对齐阶段用海量短 caption（学"图上有啥"），指令阶段用少量高质量对话（学"怎么答"）。混在一起训，模型会偏向数据量大的那类。

标准做法：阶段一冻结双塔只训桥接（对齐）→ 阶段二解冻 LLM 做指令微调 → 阶段三（可选）偏好对齐。

A14 ★★★ 对齐阶段（stage-1）为什么要冻结 LLM?

A：三个原因：

1. **保护语言能力**：桥接层初始输出没有语义，让 LLM 去适配它 = 让 LLM 学"如何理解噪声"，会破坏语言先验。
2. **训练信号更干净**：冻结 LLM 后，梯度只能改桥接层，等于在解"如何把视觉特征翻译成 LLM 能懂的词"这个子问题。
3. **成本**：只训几百万参数，单卡就能跑。

追问：那为什么有些模型（如 InternVL）在阶段一就解冻部分 LLM？→ 数据量足够大时（亿级图文对），直接联合训练能获得更强的对齐；小数据下必须冻结，否则一定崩。

A15 ★★ 指令微调数据怎么构造？有哪些来源？

A：五类来源，按质量排：

1. **人工标注**（最贵）：真实用户的问答、专家标注。
2. **强模型蒸馏**：用 GPT-4V/Claude 对图像生成多轮对话，再人工抽检。**注意只让它生成文本，不要用它生成图像**（版权与分布问题）。
3. **现有数据集改造**：VQA、检测（转成"图里有什么/在哪"）、OCR、grounding、文档理解，全部改写成对话格式。
4. **合成负样本**：故意问图中没有的东西，教模型说"没有"——**这是抑制幻觉最有效的数据手段**（对应 POPE 的 adversarial 设置）。
5. **纯文本数据混入**：防语言能力退化（见 A21）。

质量控制：去重（图像近重复是评测泄漏的头号来源）、答案长度控制（过长的回答会教模型"啰嗦"）、任务配比（OCR/推理/描述/grounding 要有比例）、难度分层。

A16 ★★ 怎么定图文 token 比例 / 数据配比？

A：没有普适公式，但有三条经验：

1. **按任务定 token 预算**：OCR/文档/grounding 需要高分辨率（给多 token），日常对话可以压缩（少 token）。
2. **按能力短板调**：评测发现哪块弱就加哪块数据（不是加权采样，而是补数据）。
3. **按阶段定比例**：对齐阶段图文对占绝对多数（可以 100%）；指令阶段通常图文 : 纯文本 ≈ 7:3 或 8:2。

监控手段：分别报"纯文本 benchmark"和"多模态 benchmark"，看是否出现"多模态涨、纯文本掉"的跷跷板。

A17 ★★ 分辨率策略有哪几种？各自代价？

A：四种：

策略	做法	token 代价	代表
固定分辨率	统一 resize 到 336/448	固定（576/1024）	LLaVA-1.5
动态切块（anyres）	大图切 N 块 + 1 张缩略图	N×576 + 576	LLaVA-1.6、InternVL
原生分辨率	按原分辨率切 patch，不缩放	与像素数成正比	NaViT、Fuyu
像素重排	2×2 patch 拼通道	÷4	InternVL

关键工程点：切块时块与块之间要**留重叠**（避免边界目标被切断），并做**位置编码的连续性处理**（否则模型不知道第 2 块在右边）。

A18 ★★ 多图 / 多轮对话在训练时怎么组织？

A：三条：

1. **特殊 token 标界**：每张图用 `<image>` / `<|image_pad|>` 包裹，模型靠这个知道"这里换了一张图"。
2. **图像只在首次出现时插入**：多轮里后续轮次引用"上面那张图"，不重复插 token（否则上下文爆炸）。
3. **loss mask**：只在 assistant 回复上算损失，用户提问和历史回复 mask 掉。

追问：多轮时历史图像 token 要不要丢？→ 上下文够就保留；不够时的常见策略是"旧图只留缩略图 token"或"旧图换成语义摘要"，本质是**压缩历史**。

A19 ★ 课程学习（curriculum）在 VLM 训练里怎么用？

A：由易到难排数据：短 caption → 长描述 → 单轮 QA → 多轮对话 → 需要推理/多图对比的难题。好处是**收敛更稳**（早期不被难题的噪声主导）、**避免早期过拟合到长答案格式**。

实践中最常见的"隐式课程"就是：对齐阶段全是短 caption（简单），指令阶段才上复杂任务。

A20 ★★ 合成数据有什么风险？

A：四个风险：

1. **分布坍缩**：全用强模型生成，学生会继承教师的偏好和错误（教师也可能幻觉）。
2. **风格单一**：句式、长度、格式趋同，模型失去多样性（用户会觉得"答得像机器人"）。
3. **事实污染**：教师对图像看错的地方，被当作"标准答案"教下去。
4. **评测污染**：合成时如果不小心用到评测集图像，指标虚高。

缓解：合成 + 人工抽检、保留一部分真实数据、拒绝采样（best-of-n 后人工/规则筛）、对合成数据降权。

A21 ★★ 混合模态训练时，怎么防止纯文本能力退化？

A：三条措施：

1. **数据层面保留纯文本**：图文:纯文本通常 7:3 ~ 8:2；SFT 阶段尤其重要。
2. **参数层面限制漂移**：用 LoRA 或只解冻部分层，减少对语言能力的破坏。
3. **评测层面同时盯**：每次报多模态分的同时报纯文本分，出现"跷跷板"就调整配比。

机制解释：图文数据的答案分布（描述性、短句）与文本数据（推理、长文）差异大，模型会向数据多的那侧偏——这叫**模态偏置**，不是简单的"遗忘"。

A22 ★★ 训练时视觉塔解冻有什么风险？什么时候该解冻？

A：**风险**：① 视觉塔参数量大，解冻后显存和算力翻倍；② 小数据下会破坏预训练特征（退化成"适配指令数据的私有特征"）；③ 与 LLM 的学习率不匹配时容易震荡。

该解冻的情况：领域差异极大（医学影像、红外、深度图、遥感）、需要极细粒度定位、数据量足够大（百万级以上）。**通常做法**：只解冻最后 1-2 层 + 小学习率（1/10），或加 LoRA。

A3 能力边界与失效模式（A23–A30）

A23 ★★★ VLM 的能力短板主要集中在哪五处？

A：

短板	表现	根因
细粒度计数	数错人数/物体数	对比学习不建模数量；token 聚合丢个体
空间关系	"左边的红球"搞错	全局对齐不建模相对位置；位置编码在视觉侧弱
精确 OCR	小字、密集文本读错	分辨率不足 + patch 太粗
视觉推理链	多步推理靠语言先验猜	训练数据里缺"看图推理"的中间步骤
grounding 精度	框偏、指代歧义	缺区域级监督；token 与像素的对应不唯一

面试加分：每说一个短板，配一句"所以工业上怎么绕"——如 OCR 靠 dynamic tiling + 专门 OCR 数据，空间关系靠显式 3D/2D 坐标输入（SpatialVLM 一类）。

A24 ★★★ 幻觉的三种成因在模型结构上分别对应什么？

A：

成因	结构层面的解释	缓解手段
语言先验主导	LLM 占了绝大部分参数，视觉 token 在序列里是"少数派"，attention 容易忽略它们	提高视觉 token 权重/数量、对比解码、加大视觉分辨率

成因	结构层面的解释	缓解手段
视觉信息不足	压缩过度（Q-Former/池化）、分辨率低 → 视觉证据本身弱	减少压缩、dynamic tiling、多图交叉验证
对齐错位	桥接层是"翻译器"，翻译错了 LLM 就会基于错误信息自信作答	对齐阶段加更多数据/多任务监督、区域级对齐

追问：为什么"加更多指令数据"不能根治幻觉？→ 指令数据教的是"怎么答"，不改变"看不看得清"；幻觉主要是**视觉证据强度**问题，得从分辨率/token/监督入手。

A25 ★★ 为什么 VLM 在计数上特别差？

A：四个原因叠加：

1. **训练目标不鼓励逐个体建模**：对比学习/生成目标都没有"必须数对"的压力。
2. **token 聚合丢失个体性**：patch 特征池化成全局语义时，5 个人和 6 个人的差异被平均掉。
3. **位置编码不显式表示"第几个"**。
4. **数据偏差**：训练数据里计数类问答少且答案分布偏（多半是"1 个""2 个"）。

能改善的做法：专门的计数数据 + 让模型输出检测框/点（"先定位再数"）+ 高分辨率。

A26 ★★ 空间关系理解为什么难？

A：因为 VLM 的语言侧对"左右上下"极敏感（文本里这两词很常见），但视觉侧**没有显式坐标系**——patch 序列的位置编码是 2D RoPE 或可学习编码，与"图像平面坐标系"不是一回事。于是模型倾向于**根据语言先验猜**（"盘子通常在下"），而不是看图。

工业解法：把坐标显式输入（"物体 A 在 (x1,y1)-(x2,y2)"）、加 3D/2D 位置监督数据、或干脆让模型先输出框再回答。

A27 ★★ OCR 能力怎么系统性提升？

A：四件事，按性价比排：

1. **分辨率**（最关键）：dynamic tiling 把长文档切成条带，每块单独编码。
2. **数据**：大量文档/表格/截图类 QA（DocVQA、ChartQA、TextVQA 一类），以及纯 OCR 转录任务。
3. **视觉塔**：patch 更小或专用 OCR 前端。
4. **后处理**：让模型输出结构化结果（JSON/表格），便于校验。

A28 ★★ VLM 做视觉 grounding 的三种输出形式？

A：① **文本坐标**（"`<box>(x1,y1,x2,y2)</box>`"）——最通用，但精度受 token 化影响（数字被切成多个 token）；② **特殊 token / 离散 bin**（把坐标量化成 bin 分类）——精度可控；③ **专用 head**（接一个检测头输出框/mask）——精度最高，但破坏了"纯语言模型"的统一性。

趋势：主流通用模型用 ①，专门的方向（指代分割、GUI agent）用 ②③。

A29 ★ 视频理解比图像多出来的难点是什么？（三条）

A：① **token 爆炸**（帧数 × 每帧 token）；② **时序建模**（帧间关系、事件先后、因果）；③ **长视频检索**（1 小时视频不可能全塞，必须"摘要 + 检索"）。附加难题：视频数据标注昂贵、评测集难做（时序问答的答案歧义大）。

A30 ★★ 为什么说"VLM 的数学推理很多时候是在做语言推理"？

A：因为它可以从题目文本推出答案（哪怕图没看对）。诊断方法很直接：**把图像遮挡/替换成无关图像，看答案是否改变**——不变就说明它没用图。这也是 HallusionBench 这类"视觉依赖测试"的设计思想。

A4 评测体系（A31–A38）

A31 ★★★ 主流评测集各自测什么？给一张能背的表。

评测集	测什么	需要记住的细节
MMBench	综合能力（20 个能力维度）	**CircularEval**：选项循环移位，全对才算对，消除位置偏置
MMMU	大学水平学科推理（图、表、公式、考试题）	多学科多图，考专业知识，人类专家也只有 ~80%
SEED-Bench	生成式理解（图+视频）	多项选择，人工校验过
POPE	**物体幻觉**	random / popular / **adversarial** 三设置；报 F1 和 yes 比例
HallusionBench	幻觉（视觉依赖 + 反事实）	专测"看图 vs 靠先验编"
MM-Vet	综合（识别+推理+OCR 交叉）	GPT-4 打分，看能力维度组合
RefCOCO/+/g	指代定位 grounding	Acc@0.5（IoU>0.5）或点命中率
TextVQA / DocVQA / ChartQA / OCRBench	OCR 与文档	工业落地最常看这四个
MathVista	数学视觉推理	图表+几何+公式
VideoMME / LongVideoBench	视频（短/中/长，有无字幕）	必须**分时长档**报，长视频普遍崩

A32 ★★★ CircularEval 是什么？为什么必须有？

A：把一道多选题的选项**循环移位 N 次**（N = 选项数），每次让模型作答，**N 次全对才算答对**。

原因：VLM 对选项位置有强烈偏置（训练数据里 A/B 出现频率高、或 token 化后某些位置的概率先验高），不移位会系统性高估能力——有研究报告这个偏差能贡献 10+ 个点的虚高。

面试意义：讲得出 CircularEval，等于告诉面试官"我读过评测实现，不只看排行榜数字"。

A33 ★★ POPE 的三个设置为什么要区分？

A：因为负样本的难度决定评测的可信度：

- **random**：随机挑不存在物体 → 太简单，模型靠"这词常见"就能答对；
- **popular**：挑数据集中高频但图里没有的物体 → 中等；
- **adversarial**：挑**与图中物体共现频率高**的物体（有椅子就问"有桌子吗"）→ 真考验"是否在看图"。

只看 random 分数会严重虚高，三个设置一起报才有意义。

A34 ★★ 评测里最容易自欺的四个地方？

A：① **数据泄漏**（训练图和评测图近重复，CLIP 系预训练数据几乎覆盖全网）；② **prompt 敏感**（换模板差几个点，不报 prompt 就是不完整）；③ **选项偏置**（不做 CircularEval）；④ **只报总分**（不报分项，OCR 强推理弱看不出来）。

加分补一句：还要报 **解码配置**（贪心/beam/温度）和**是否 few-shot**——这些不写，结果不可复现。

A35 ★★ 幻觉怎么量化？除了 POPE 还有什么办法？

A：四类方法：

1. **判别式探测**（POPE）：问"有没有 X"，看 yes/no 是否正确 → 简单、可自动化；
2. **生成式一致性**：同一张图问多次/换问法，答案不一致即为不稳定（self-consistency 视角）；
3. **视觉依赖测试**：把图替换成空白/无关图，答案不该变（该变才说明用了图）；
4. **人工/强模型打分**：MM-Vet 式，成本高但是最终裁判。

A36 ★★ grounding 的评测为什么比检测的 mAP 更"宽容"?

A：因为 grounding 的目标是"**指代唯一性**"而不是"检测全面性"：输入是一句描述，只要求找到**那个**目标，不惩罚漏检其他物体。指标常用 Acc@0.5 或点命中（点落在 GT mask 内），后者更宽容（不要求框贴合）。

难点在指代歧义：图里有三只狗，"那只左边的狗"需要理解关系，而不是靠类别先验。

A37 ★ 长视频评测为什么必须分档报?

A：短视频（<2 分钟）靠帧采样就能覆盖，模型表现接近图像；中长视频开始依赖时序推理与检索，性能断崖式下降。**只报平均分会掩盖这个断崖**——所以 VideoMME 明确分短/中/长三档，并区分有无字幕（有字幕时模型可能"读字幕"而不看画面，这也是要看分项的原因）。

A38 ★★ 怎么评测"模型有没有真在看图"？设计一个实验。

A：三个可落地实验：

1. **图像替换**：换成同类无关图 → 答案应显著改变（不变 = 没用图）。
2. **局部遮挡**：遮住关键区域 → 答案应变差（不变 = 没依赖该区域）。
3. **反事实图像**：把"红色苹果"改成蓝色 → 答案应跟着变（不变 = 靠先验）。

这三个也是 HallusionBench 的核心思想。**面试时能讲出实验设计，比背分数有用。**

A5 推理与部署（A39–A45）

A39 ★★★ VLM 推理的延迟构成？哪一段是瓶颈?

A：四段：① **预处理**（resize/切块/归一化，CPU 上常被忽略但很贵）；② **视觉塔前向**（与分辨率平方相关）；③ **prefill**（把图文 token 一次前向，计算密集）；④ **decode**（逐 token，访存密集，与输出长度线性）。

瓶颈判断： - 高分辨率 + 短回答 → 卡在 ②③（视觉塔 + prefill）； - 低分辨率 + 长回答 → 卡在 ④（decode，KV cache 带宽）。

这句话很值分："端侧 VLM 要先分清是 prefill-bound 还是 decode-bound，两者的优化手段完全不同。"

A40 ★★ VLM 的 KV cache 和纯文本 LLM 有什么不同?

A：机制一样（缓存每层 K/V），但 VLM 有两处特殊：

1. **视觉 token 的 KV 是固定的**：同一张图多轮问答时，视觉部分的 KV 可以**跨轮复用**（prefix cache 思路）——这是多模态特有的优化收益。
2. **视觉 token 数量大且不等于文本长度**：一张 anyres 图可能 2880 token，KV cache 直接翻几倍，长多轮时显存爆得比纯文本快得多。

A41 ★★ 图像 token 太多，有哪些工程压缩手段?

A：五类：① 视觉侧压缩（pixel shuffle、池化）；② 桥接层压缩（Q-Former/resampler）；③ token 剪枝（按注意力重要性保留 top-k）；④ 动态分辨率（按任务给 token）；⑤ 缓存复用（同一图的多轮只算一次）。

面试提醒：压缩一定损精度，所以要说清"在哪一层压、损失什么"——通道压缩损细节，序列压缩损定位，两者可叠加但要注意叠加放大误差。

A42 ★★ VLM 量化有什么特别的坑?

A：三个：① **视觉塔对量化更敏感**（输入分布极端、动态范围大），常见做法是视觉塔保 FP16、只量化 LLM；② **视觉 token 的离群值**（ViT 输出常有较大激活）会破坏 INT8，需要 per-channel 或对视觉通路单独处理（类似 AWQ 保护重要通道）；③ **KV cache 量化**在多轮/长上下文里收益最大，但要单独校准。

A43 ★ 投机解码能用在 VLM 上吗?

A：能，但草稿模型的输出分布要覆盖**图文场景**——用纯文本小模型做草稿，遇到需要"看细节"的问题命中率会掉。实践中：① 用同系列的小 VLM 作草稿；② 或者只在"回答格式固定/重复性高"的场景（如结构化抽取）用。

A44 ★★ 端侧 VLM 的现实约束是什么?

A：四条硬约束：① **内存**（权重 + KV cache + 激活，手机级别只有几 GB 可用）；② **算子支持**（动态形状、动态分辨率、attention 变体在 NPU 上常常要改）；③ **功耗/发热**（长时间推理会降频）；④ **预处理开销**（切块/resize 在 CPU 上可能比模型还慢）。

你的接口（可直接讲）："我在 MDC610 上做过 ONNX→ATC/AOE 的完整链路，所以端侧 VLM 我会先问三件事——**目标 SoC 的算子白名单、内存预算、是否允许动态分辨率**。"

A45 ★ 昇腾/国产芯片上部署 VLM，主要工作量在哪?

A：四块：① **算子适配**（不支持的算子拆解或等价重写，例如动态 attention、top-k、动态 shape）；② **shape 固定化**（把动态分辨率按档位枚举，分桶推理）；③ **精度对齐**（fp16 溢出、算子融合顺序导致的数值差异，要逐层比对）；④ **内存规划**（模型段/工作空间手工分配，KVCache 动态增长需要预分配）。

Part B 机器学习算法原理

> 这一部分**不写代码**（代码在手撕两册里），只讲**定义、推导、性质、对比、失效场景**——面试官问"为什么"的时候用。

B1 Softmax 家族（B1–B8）

B1 ★★★ 写出 softmax，它的雅可比矩阵是什么?

A:

```
softmax(z)_i = exp(z_i) / Σ_j exp(z_j)
```

雅可比（这个能推出来很加分）：

```
∂p_i/∂z_j = p_i · (δ_ij − p_j)     即   J = diag(p) − p · pᵀ
```

含义：**对角线是 p_i(1−p_i)（自身对自身的敏感度），非对角线是 −p_i p_j（此消彼长）**，因为输出必须和为 1，抬高一个必然压低其他。

两个关键性质：1. **平移不变**：`softmax(z + c) = softmax(z)`（分子分母同乘 e^c）。 2. **和为 1 且恒正**：输出可解释为概率单纯形上的一点。

B2 ★★★ 为什么要减 max? 给出严格的数值论证。

A：`exp(x)` 在 float32 下 x > 88.7 就上溢成 `inf`，`inf/inf = nan`。减 max 后：

```
softmax(z)_i = exp(z_i − m) / Σ_j exp(z_j − m)，其中 m = max_j z_j
```

- **数学等价**：分子分母同乘 `e^{-m}`，结果不变（这是"等价"，不是近似）。
- **数值安全**：减完后最大项是 `exp(0)=1`，其余 ≤ 1，不会上溢；小项下溢成 0 也无害（softmax 里 0 就是"几乎不可能"）。
- **但下溢在 log 域有害**：如果先算 softmax 再取 log，下溢成 0 的地方会变 `-inf`。所以**交叉熵要直接在对数域算**（log_softmax / logsumexp），这是工程上的标准做法。

追问：全 −inf 的一行会怎样？→ 分母 0 → NaN。所以 mask 用 `-1e9` 而不是 `-inf`，或对全屏蔽行单独补 0。

B3 ★★★ 推导 softmax + 交叉熵的梯度为什么是 `p − y`。

A：设 `L = −log p_y = −z_y + log Σ_j exp(z_j)`。

对 `z_i` 求导，分两种情况：

```
∂L/∂z_i = −δ(i=y) + exp(z_i)/Σ_j exp(z_j) = p_i − δ(i=y)
```

即 **`∂L/∂z_i = p_i − y_i`**（y 是 one-hot）。

这个结果的意义：1. 梯度**不含 softmax 的雅可比**——两者精确抵消了（这也是框架把 softmax+CE 合成一个算子（如 `F.cross_entropy`）的原因：更快、更稳）。2. 误差越大梯度越大（预测 0.1、真值 1 → 梯度 −0.9），**没有饱和问题**；3. 对比 MSE + softmax：后者梯度多一个 `p(1−p)` 因子，在"预测 0.99 但真值是 0"这种最该纠错的情况下梯度趋于 0。

B4 ★★ softmax 的温度参数有什么作用?

A：`softmax(z/T)`：

- `T = 1` 标准；
- `T > 1` → 分布更平（熵更大），用于**知识蒸馏**（软标签含"类间相似性"信息）、**采样多样性**、**LLM 生成**；
- `T < 1` → 分布更尖（接近 argmax），用于确定性输出；
- `T → 0` → 退化成 one-hot（hard max）；`T → ∞` → 均匀分布。

为什么蒸馏要用 T：教师模型的原始 logits 里，"猫"和"狗"的相似性会被 softmax 压成接近 0 和 1，T 放大后这部分"暗知识"才显现出来，学生才能学到。

B5 ★★ softmax 存在"过参数化"，怎么理解?

A：`softmax(z + c·1) = softmax(z)` ——**所有 logit 同加一个常数，输出不变**。所以：- C 类分类实际只有 **C−1 个自由度**，参数矩阵存在一整个方向的冗余（解不唯一）；- 导致 Hessian 奇异、优化不唯一、某些正则化行为异常。

三种处理：① 固定某一类的 logit 为 0（等价于用 C−1 组参数，这在数学上恰好等价于 sigmoid 二分类的推广）；② 加 L2 正则（把解拉向唯一）；③ 干脆不管（深度学习里因为正则/优化噪声，实践中不影响）。

B6 ★★ softmax 和 sigmoid 是什么关系?

A：**二分类时两者等价**（差一个常数偏移）：

```
softmax([z, 0])_1 = e^z/(e^z+1) = σ(z)
```

所以"softmax + CE"在 C=2 时与"sigmoid + BCE"给出相同的决策边界和梯度形式。

关键区别在多标签：如果一个样本可以同时属于多个类（不互斥），必须用**逐元素 sigmoid + BCE**，因为 softmax 强制各类概率和为 1（互斥假设）。

B7 ★★ log_softmax 与 logsumexp 技巧是什么?

A：

```
log_softmax(z)_i = z_i − logsumexp(z),   logsumexp(z) = m + log Σ_j exp(z_j − m)
```

- 直接算 `log(softmax(z))` 会先下溢再取 log → `−inf`；log_softmax 全程在对数域，**数值稳定**。
- `logsumexp` 是核心恒等式：**先减最大值，算完再加回来**。它出现在交叉熵、CRF、变分推断、混合模型里。
- 工程上 `torch.logsumexp` 已内置该实现；手写时**务必自己减 max**。

B8 ★ softmax 在什么情况下梯度会消失？怎么缓解?

A：当某个 logit 远大于其他（`z_max − z_second ≫ 0`）时，softmax 输出接近 one-hot，`p_i(1−p_i) → 0`，**梯度饱和**。这在训练早期 logit 尺度过大时容易出现（初始化不好、学习率过大、输入未归一化）。

缓解：① 输出层用小初始化（或用温度缩放）；② 加 label smoothing（防止一路把概率推到 1）；③ 用 focal loss（主动放大难例权重）；④ 检查输入特征尺度与归一化。**这也是"训练初期 loss 不动"的常见原因之一。**

B2 信息熵与信息论（B9–B16）

B9 ★★★ 信息量和熵的定义与直觉?

A:

- **自信息**：$I(x) = -\log p(x)$。概率越小，事件发生带来的"信息量"越大（小概率事件更有信息）。
- **熵**（信息熵）：$H(X) = -\Sigma_x p(x) \cdot \log p(x) = E[-\log p(X)]$，即**平均信息量 / 不确定度**。
- 单位：log 以 2 为底是 bit，以 e 为底是 nat（深度学习多用 nat）。
- **极值**：均匀分布熵最大（最不确定）；确定性分布熵为 0。

一句话直觉：熵 = "描述这个随机变量平均需要多少比特" = "我猜它有多难"。

面试常配的追问：为什么熵是不确定度的合理度量？→ 三条公理（连续性、均匀分布最大、独立可加）唯一确定出 $-\Sigma p \log p$ 的形式（Shannon 唯一性定理）。

B10 ★★★ 联合熵、条件熵、链式法则?

A:

```
联合熵    H(X,Y) = −ΣΣ p(x,y) log p(x,y)
条件熵    H(Y|X) = H(X,Y) − H(X)          （给定 X 后 Y 的剩余不确定度）
链式法则  H(X,Y) = H(X) + H(Y|X)
```

重要性质：- $H(Y|X) \leqslant H(Y)$：知道 X **不会增加** Y 的不确定度（等号当且仅当独立）。- $H(X,Y) \leqslant H(X) + H(Y)$：等号当且仅当独立。

在树模型里怎么用：ID3 的信息增益本质就是 $H(D) - H(D|A)$，即"用特征 A 划分后，标签的不确定度减少了多少"。

B11 ★★★ 互信息是什么？有什么意义?

A:

```
I(X;Y) = H(X) − H(X|Y) = H(Y) − H(Y|X) = H(X) + H(Y) − H(X,Y)
```

含义：知道 Y 能减少多少关于 X 的不确定性（对称的"相关性"度量）。

三个用途（面试可举）：1. **决策树的信息增益** = $I(\text{标签};\ \text{特征})$；2. **特征选择**：互信息高 = 该特征与标签相关性强；3. **多模态对齐的另一种视角**：CLIP 的 InfoNCE 本质在最大化**图像与文本的互信息下界**（这是理解对比学习的信息论视角）。

B12 ★★★ KL 散度的定义与三个性质?

A:

```
D_KL(P||Q) = Σ_x p(x) · log( p(x)/q(x) )
```

三个性质：1. **非负**：$D_{KL} \geqslant 0$，等号当且仅当 P=Q（由 Jensen 不等式或 Gibbs 不等式）。2. **非对称**：$D_{KL}(P||Q) \neq D_{KL}(Q||P)$，所以**不是距离**（不满足三角不等式）。3. **不度量"距离"而度量"代价"**：$D_{KL}(P||Q)$ 是"用 Q 去编码 P 的额外代价"。

非对称的实际后果（这个例子很值分）：设 P 是双峰分布，Q 是单峰高斯：- **前向 $KL(P||Q)$**（最小化 Q 覆盖 P 的所有模式）→ Q 会摊平成宽分布，**mass-covering**；- **反向 $KL(Q||P)$**（Q 避开 P 概率为 0 的地方）→ Q 会塌到某个峰，**mode-seeking**。这就是变分推断（前向）与 GAN/反向 KL 行为差异的根源。

B13 ★★★ 交叉熵和 KL 散度的关系？为什么分类要用交叉熵?

A:

```
H(P,Q) = −Σ p log q = H(P) + D_KL(P||Q)
```

即 **交叉熵 = 真实分布的熵 + KL 散度**。因为 $H(P)$ 与模型参数无关（数据固定），所以：

最小化交叉熵 ≡ 最小化 KL 散度，即让预测分布尽量逼近真实分布。

用交叉熵而不用 KL 的工程原因：**不需要知道 H(P)**（P 是 one-hot 时 H(P)=0，直接就是 −log q_y），计算更简单。

一句话：交叉熵是"用模型分布去编码真实标签的代价"，最小化它就是最大似然估计。

B14 ★★★ 信息增益怎么算？它偏向什么？

A：

```
Gain(D, A) = H(D) − Σ_v (|D_v|/|D|)·H(D_v) = H(D) − H(D|A) = I(D; A)
```

即"用特征 A 划分后标签熵的下降量"，也就是互信息。

偏向多值特征：特征取值越多，划分得越细，`H(D|A)` 越容易小（极端情况：用 ID 号划分，每个样本一组，增益最大但毫无泛化）——**这是 ID3 的根本缺陷**，被 C4.5 的增益率修正。

B15 ★★ 信息增益率与固有值是什么？为什么能修正偏向？

A：

```
增益率 = Gain(D, A) / IV(A),   IV(A) = −Σ_v (|D_v|/|D|)·log(|D_v|/|D|)
```

`IV(A)` 是特征 A 自身的**固有值/分裂信息**（把样本按 A 分成 v 组的"熵"），取值越多 IV 越大，于是增益率被惩罚。

但增益率也有反向偏向（偏向取值少的特征），所以 C4.5 用的是**启发式**：先找出增益高于平均的特征，再在其中选增益率最高的。

B16 ★★ 基尼指数和熵是什么关系？为什么 CART 用基尼？

A：

```
基尼    Gini = 1 − Σ_c p_c²   =  Σ_{c≠c'} p_c p_{c'}     （随机取两个样本、类别不同的概率）
熵      H = −Σ_c p_c log p_c
```

- **形状高度相似**：都在均匀分布处取最大，都在纯节点处取 0；二分类下 `Gini = 2p(1−p)`，与熵的曲线几乎重合。
- **基尼是熵的近似**（在均匀分布附近可用低阶展开近似），所以划分结果基本一致。
- **用基尼的原因**：只有乘法加法、**没有 log**，计算快（大数据下差异明显）；且梯度更"平缓"，对噪声略鲁棒。

追问：两者的最优划分会不同吗？→ 可能不同，但实践差异很小；论文级对比显示 mIoU/准确率差异通常在 1% 内。

补充：还有 **最大熵原理**（在已知约束下选熵最大的分布，最"不假设"）和 **困惑度**（`perplexity = exp(H)`，语言模型常用），面试顺口提到很加分。

B3 分类树（B17–B28）

B17 ★★★ ID3 / C4.5 / CART 三种算法怎么对比？

A：

	ID3	C4.5	CART
划分准则	信息增益	**信息增益率**	**基尼指数**（分类）/ MSE（回归）
分裂方式	**多叉**（每个取值一支）	多叉	**二叉**
连续特征	不支持	支持（排序+二分）	支持
缺失值	不支持	支持（按权重分配到各分支）	支持（代理分裂 surrogate split）
剪枝	无	悲观剪枝（PEP）	**代价复杂度剪枝（CCP）**
输出	分类	分类	**分类 + 回归**

一句话："ID3 是原型，C4.5 补工程（连续/缺失/剪枝），CART 补统一性（二叉 + 回归）——sklearn 和所有 GBDT 家族用的都是 CART。"

B18 ★★★ 为什么 CART 用二叉树?

A：四个理由：

1. **避免碎片化**：多叉会让样本被迅速切碎（取值多的特征尤其），每个分支样本太少 → 过拟合且统计不可靠。
2. **表达力更强**：二叉允许**同一特征被多次使用**（"年龄<30 且 年龄>20"），而多叉一个特征只能用一次。
3. **计算高效**：每次只需找最优二分点，比多路划分的组合搜索简单得多。
4. **统一处理类别型特征**：把"取值集合"按 one-vs-rest 二分（对类别特征做分组），天然支持"把 {红,蓝} 归一边"。

B19 ★★★ 连续特征怎么处理？为什么只需枚举相邻中点?

A：做法：该特征的所有取值**排序去重** → 只在**相邻不同取值的中点**试切分。

为什么只需相邻中点：对同一特征，若两个阈值落在同一对相邻取值之间，**划分出的样本集合完全相同**（因为区间内没有样本），所以只有 n−1 个"有效"候选阈值（n = 去重后取值数），彼此等价。

复杂度：排序 $O(n \log n)$ + 一次扫描 $O(n)$（用前缀计数增量更新左右子集的不纯度），而不是"每个阈值重扫一遍"的 $O(n^2)$。

追问：为什么要去重？→ 相同取值的样本任何阈值都分不开，切开是无意义分裂。

B20 ★★★ 剪枝的三种方式？代价复杂度剪枝怎么工作?

A：

方式	做法	优缺点
预剪枝	提前停：深度上限、叶最小样本、增益阈值、纯度阈值	快；但**贪心视野短**，可能过早停止（当前增益小、后续收益大）
后剪枝	先长满，再自底向上判断"是否合并叶子"	更准（看到全树后再决策），但训练成本高
CCP（代价复杂度）	定义 $R_\alpha(T) = R(T) + \alpha \cdot \lvert T \rvert$（R 是训练误差，	T

CCP 的机制：α=0 时最优是全树；α 增大时叶子的"惩罚"变重，逐步剪枝 → 得到一串嵌套子树 → 用验证集选最好的 α（sklearn 的 `ccp_alpha`）。

面试话术："预剪枝省时但短视，后剪枝准但贵；工业上常见组合：先用预剪枝控深度（防止爆内存），再用后剪枝微调。"

B21 ★★ 缺失值怎么处理?

A：两种主流：

- **C4.5**：把缺失样本**按权重分到所有分支**（权重 = 各分支样本比例），增益计算时乘上"有效样本比例"的折扣因子。
- **CART（sklearn 不支持，但理论上有）**：**代理分裂（surrogate split）**——为每个主分裂再学若干"代理特征"，推理时若主特征缺失，用与它最相似的代理特征代替。

工程实践：多数框架直接要求先填充缺失值（均值/中位数/模型预测），再建树——因为树分裂的代理机制实现复杂且收益不稳定。

B22 ★★ 回归树怎么建？叶子输出什么?

A：和分类树完全同构，只换两处：

1. **划分准则**：从基尼换成 **MSE 下降**（$MSE = (1/n)\Sigma(y-\bar{y})^2$）。
2. **叶子输出**：从"多数类"换成 **均值**（最小化平方误差的最优常数就是均值；若损失是 MAE，则取**中位数**）。

注意：回归树的预测是**分段常数**（一个叶子一个值），所以它**不能外推**（超出训练范围的值只能给边界值），且对目标做单调变换会改变结果（因为 MSE 不等变）。

B23 ★★★ 特征重要性怎么算？有什么偏差？

A：两种：

1. **不纯度重要性（Gini/MSE importance，sklearn 默认）**：把"该特征每次分裂带来的加权不纯度下降 × 样本数"累加后归一化。
2. **置换重要性（permutation importance）**：打乱该特征的值（破坏其与标签的关系），看验证指标下降多少。**更可靠、更贵**。

三种已知偏差：- **偏高基数/多值特征**（分裂机会多，累积下降自然大）；- **对相关特征会"分摊"**（两个高度相关的特征各拿一半，看起来都不重要）；- **在不纯度重要性里，训练集上计算会偏向能拟合噪声的特征**。

面试加分："所以我一般用置换重要性做最终判断，不纯度重要性只用来看相对排序。"

B24 ★★ 决策树为什么不稳定？为什么要集成？

A：**不稳定**的原因：树的分裂是**贪心的离散选择**——数据微扰（换一批样本、加几个噪声点）可能让最优切分点改变，后面的整棵子树结构随之变化，预测方差大。

偏差-方差视角：单棵树**偏差低（可以拟合很复杂的边界）、方差高**。所以：- **Bagging / 随机森林**：并行多棵 + 平均 → **降方差**（不显著降偏差）；- **Boosting / GBDT**：串行拟合残差 → **降偏差**（同时要控制方差，所以用小树 + 学习率）。

B25 ★★★ RF / GBDT / XGBoost / LightGBM / CatBoost 怎么串起来？

A：

	集成方式	优化目标	关键创新
随机森林	Bagging（样本 + 特征双采样，并行，投票/平均）	降方差	双重随机性让树之间去相关
GBDT	Boosting（串行，每棵树拟合**负梯度/残差**）	降偏差	用树做梯度下降
XGBoost	GBDT + 工程	二阶泰勒 + 显式正则	二阶信息、正则化（$\gamma T + \lambda w^2/2$）、稀疏感知、特征级并行、近似分位点
LightGBM	GBDT + 效率	同 XGB	**leaf-wise 生长**（同一叶数下更低 loss，但易过拟合，需控 `num_leaves`）、直方图分桶、**GOSS**（保留梯度大的样本）、**EFB**（互斥特征捆绑）
CatBoost	GBDT + 类别特征	同 XGB	**对称树（oblivious）**、**ordered boosting**（解决目标泄漏）、类别特征的有序目标编码

一句话链："RF 是并行降方差，GBDT 是串行降偏差；XGBoost 给 GBDT 加了二阶和正则，LightGBM 把速度做到极致，CatBoost 专治类别特征。"

B26 ★★ XGBoost 相对传统 GBDT 的关键改进？

A：四件事：

1. **二阶泰勒展开**：目标函数用一阶梯度 g + 二阶 h 近似，**最优叶权重有闭式解** $w^* = -\Sigma g/(\Sigma h+\lambda)$，分裂增益也有解析式。这比只用一阶梯度收敛更快、更准。
2. **显式正则**：$\Omega = \gamma T + (\lambda/2)\Sigma w^2$，直接在目标函数里惩罚树复杂度（叶数 T 和叶权重 w），而不是靠早停/剪枝。
3. **稀疏感知**：为缺失值学一个默认方向（分裂时把缺失样本统一分到增益大的一侧）。
4. **工程**：特征预排序（block 结构）、特征级并行、近似分位点（`approx_hist`）、缓存优化。

B27 ★★ LightGBM 的 leaf-wise、GOSS、EFB 分别解决什么？

A：

- **leaf-wise（按叶生长）**：每次选"增益最大的叶子"继续分裂，而不是按层。同样的叶数下 loss 更低（效率高），但**容易长出深的不平衡树 → 过拟合**，所以要用 `num_leaves` 和 `max_depth` 双重约束。

- **GOSS（Gradient-based One-Side Sampling）**：梯度大的样本对增益贡献大，**保留全部大梯度样本 + 随机采样一部分小梯度样本**（并放大权重），用少量样本近似全量增益。
- **EFB（Exclusive Feature Bundling）**：稀疏场景下很多特征互斥（不会同时非零），把它们**捆绑成一个特征**，降低特征维度 → 减少直方图构建开销。

B28 ★ 什么时候选树模型，什么时候选线性/神经网络?

A:

场景	选树	选线性/NN
表格数据、中小规模、需要可解释	✅树（尤其 GBDT，仍是表格任务的王者）	—
高维稀疏（文本 TF-IDF）	—	✅线性（快、可解释）
特征有强交互、非线性	✅树	✅NN（需更多数据）
需要外推（预测超出训练范围）	❌树不能外推	✅线性/NN
需要平滑输出	❌分段常数	✅
图像/语音/文本原始信号	—	✅深度模型

一句话："树赢在'不需要特征工程 + 自动做交互 + 可解释'，输在'不能外推、不平滑、不稳定'。"

B4 K-Means（B29–B36）

B29 ★★★ KMeans 的算法与目标函数?

A:

目标函数（inertia / 簇内平方和）：

```
J(C, μ) = Σ_i min_j ||x_i − μ_j||²
```

算法（交替优化 / 坐标下降）：

```
1. 初始化 k 个中心
2. E 步（固定中心）：把每个点分给最近的中心
3. M 步（固定分配）：把每个中心更新为其簇内所有点的均值
4. 重复 2-3 直到中心移动量 < tol 或达到迭代上限
```

为什么 M 步是均值：固定分配后，$J = \Sigma_j \Sigma_{i \in C_j} ||x_i - \mu_j||^2$ 对 μ_j 求导置零，得 $\mu_j = (1/|C_j|)\Sigma\, x_i$ ——即**均值是最小化平方误差的最优常数**。

B30 ★★★ 为什么 KMeans 一定收敛？为什么只是局部最优?

A:

收敛：E 步（在固定中心下，把点分给最近中心）不会增大 J；M 步（固定分配下取均值）也不会增大 J。J 单调不增且有下界 0；而划分方案是**有限个**（n 个点分到 k 个簇，最多 k^n 种，实际远少），所以不会无限循环 → **有限步内收敛到一个驻点**。

局部最优：因为 J 非凸，交替优化只保证到达**坐标下降的局部极小**。初始化不同 → 收敛到不同的局部解（我实测一组数据：20 个随机种子里有 7 个没能正确分出三个簇，最差的只对上 125/150）。

工程对策：`n_init` 多次随机初始化取 inertia 最小；或 k-means++ 初始化。

B31 ★★★ k-means++ 的原理？为什么有效?

A：**D^2 采样**：

```
1. 第一个中心均匀随机选一个点
2. 之后每个新中心按概率 ∝ D(x)² 采样（D(x) = 到最近已有中心的距离）
3. 重复到选出 k 个
```

即"**离已有中心越远的点，越容易被选为新中心**"。

为什么有效：随机初始化最坏情况可能把两个中心都放在同一个真实簇里（剩下一个簇分不到中心），D^2 采样让中心天然分散，规避了这种退化。

理论保证：k-means++ 的期望代价 ≤ **O(log k)** 倍最优解（对比随机初始化的任意差）。代价只是初始化时多算几次距离。

B32 ★★★ k 怎么选？（四种方法）

A：

1. **肘部法（elbow）**：画 inertia-k 曲线，找拐点（边际收益骤降处）。缺点是"肘"常常不明显。
2. **轮廓系数（silhouette）**：`s = (b − a)/max(a, b)`，a = 到本簇其他点的平均距离，b = 到最近其他簇的平均距离。范围 [−1,1]，越大越好，取 s 平均最大的 k。
3. **Gap statistic**：比较 log(inertia) 与"零假设下（均匀分布）的期望值"的差，差距最大处为最优 k。
4. **稳定性 / 下游指标**：多次子采样聚类的一致性；或直接用下游任务指标（最实际）。

面试加分："我更看重**稳定性**——k 稍微变化时簇结构是否稳定；如果 k=4 和 k=5 的划分看起来完全不同，说明数据本身没有清晰的簇结构。"

B33 ★★ KMeans 的复杂度？怎么加速？

A：**O(n · k · d · t)**（n 样本、k 簇、d 维、t 迭代轮数）。空间 O(n · d + k · d)。

加速手段： 1. **MiniBatch KMeans**：每步只用一个小 batch 更新中心（`O(b · k · d · t)`），大规模数据首选。 2. **Elkan 算法**：用三角不等式剪枝，跳过不可能更近的中心计算。 3. **kd-tree / ball-tree**：低维（d < 20）时加速最近邻搜索。 4. **降维**（PCA/随机投影）后再聚类。 5. **初始化用 k-means++ + n_init 小**（减少迭代次数）。

B34 ★★ KMeans 的假设与失效场景？

A：四个隐含假设：

1. **簇是凸的、球形的**（欧氏距离隐含等向性）→ 遇到月牙形/环形数据直接失效（该用 DBSCAN/谱聚类）。
2. **各簇方差相近、大小相近** → 一个大簇会被劈成两半去迁就小簇。
3. **欧氏距离有意义** → 高维下距离集中（所有点距离都差不多），聚类失效。
4. **对异常值敏感** → 均值被拉走（可用 k-medoids / 截断损失）。

另外：它只给**硬分配**，不能表达"某个点 60% 属于簇 A"（要软分配用 GMM）。

B35 ★★ KMeans / GMM / DBSCAN / 层次 / 谱聚类怎么选？

A：

方法	核心思想	优点	缺点
KMeans	中心 + 硬分配	快、简单、可扩展	球形假设、要指定 k、异常敏感
GMM（EM）	高斯混合 + 软分配	概率输出、允许不同协方差（椭圆簇）	要指定 k、对初始化敏感、高斯假设
DBSCAN	密度可达	不用指定 k、能找任意形状、能识别噪声	对 eps/minPts 敏感、密度差异大时失效、高维差
层次聚类	自底向上合并 / 自顶向下分裂	不用指定 k、给树状结构、可解释	$O(n^2)$/$O(n^3)$、不可回溯（贪心合并）
谱聚类	图拉普拉斯特征分解	能处理非凸簇	要指定 k、大图贵（需稀疏近似）

KMeans 与 GMM 的关系（高频追问）：KMeans 是 GMM 的**特例**——所有簇共享各向同性协方差 $\sigma^2 I$ 且 $\sigma \to 0$ 时的硬分配极限。EM 的 E 步是软分配（后验概率），M 步更新均值/协方差/权重。

B36 ★ 空簇和初始化有哪些实际陷阱?

A：三个：

1. **空簇**：某轮没有点分给它 → 均值无定义（除零）。处理：保留旧中心、或把它重置到"离其他中心最远的点"、或直接删掉该簇（k 减一）。
2. **初始中心重复**：随机抽到同一个点（k 接近 n 时概率不低）→ 退化。用 `replace=False` 抽样或 k-means++。
3. **用整数存中心**：均值可能是小数，用 int 会累积误差甚至震荡不收敛（这是实现 bug，但很常见）。

收敛判据的选择：用"中心移动量 < tol"而不是"标签不再变化"——后者在某些数据上会出现**标签循环震荡**（目标函数不变但分配在两组等价解之间跳）。

B5 自注意力（B37–B45）

B37 ★★★ 写出 self-attention 的完整定义，并说明每一步的形状。

A：

```
Q = X · W_Q,  K = X · W_K,  V = X · W_V          X: [L, d],  W: [d, d]
A = softmax( Q · Kᵀ / √d_k + mask , dim=-1)  Q · Kᵀ: [L, L]
O = A · V                                   [L,L]×[L,d] → [L, d]
```

三步的语义： 1. **打分**：`Q · Kᵀ` 得到任意两 token 的相似度（**全局**、与距离无关）； 2. **归一化**：逐行 softmax → 每个 query 对所有 key 的注意力分布（和为 1）； 3. **聚合**：用注意力权重对 V 加权求和 → 每个位置得到"按相关性混合"的新表示。

三个矩阵的不同角色：Q 是"我要找什么"，K 是"我能被什么匹配"，V 是"匹配上之后提供什么内容"。

B38 ★★★ 为什么除以 √d_k? 给出方差论证。

A：设 `q, k` 各维独立同分布、均值 0、方差 1，则点积：

```
q · k = Σ_{i=1}^{d_k} q_i · k_i
E[q · k] = Σ E[q_i]E[k_i] = 0
Var[q · k] = Σ Var(q_i k_i) = Σ E[q_i²] · E[k_i²] = d_k        (独立性 + 零均值)
```

所以点积的**标准差是 √d_k**——d_k=64 时量级约 8，d_k=256 时约 16。softmax 的输入尺度一大，就会进入**饱和区**（最大项 ≈1、其余≈0），此时雅可比 `diag(p)−ppᵀ ≈ 0`，**梯度消失**。

除以 √d_k 后方差回到 1，softmax 落在梯度良好的区间。**这也是 d_k 越大越需要缩放的原因。**

B39 ★★★ self-attention 的复杂度? 优化方向有哪些?

A：

```
时间: O(L² · d)      (打分 L²d + 加权 L²d)
显存: O(L² + L · d)  (要存注意力矩阵 L²)
```

L 是序列长度，所以**长上下文是平方级代价**。五个优化方向：

1. **IO 优化**：**FlashAttention**——分块（tiling）+ 在线 softmax，不把 L×L 矩阵落到显存，**省显存和 HBM 读写，不减少 FLOPs**。
2. **稀疏/滑窗**：Longformer（滑窗 + 全局 token）、BigBird（随机 + 窗口 + 全局）。
3. **低秩/核近似**：Linformer（对 K/V 降维）、Performer（核函数近似 softmax）。
4. **共享 KV**：MQA/GQA（主要省推理 KV cache）。
5. **换范式**：线性注意力、状态空间模型（Mamba，线性复杂度）。

B40 ★★★ 多头的作用是什么? 参数量怎么算?

A：把 `d` 维按**列**切成 h 份，每份 `d_k = d/h`，各自做 attention，再把 h 个 `[L, d_k]` 输出**按列拼回** `[L, d]`，最后过输出投影 `W_O`。

作用：不同头在**不同的子空间**学不同的依赖模式（相邻、句法、指代、跨模态对应），类似 CNN 的多通道分工。**计算量几乎不变**（$h \cdot L^2 \cdot (d/h) = L^2 \cdot d$），只是注意力的"视角"变多。

参数量：$4d^2$（Q/K/V/O 各 d×d）+ bias $4d$，**与 h 无关**（这是常被考的常识）。

B41 ★★★ 为什么需要位置编码？四种方案的取舍？

A：**self-attention 是置换等变的**（打乱输入只是打乱输出行），本身不含顺序信息，所以必须显式注入位置。

方案	做法	优点	缺点
正弦绝对编码	不同频率的 sin/cos	无需学习、可外推到更长	表达力弱、外推质量差
可学习绝对编码	每个位置一个向量	简单、效果好	**不能外推**（超过训练长度没有参数）
RoPE（旋转）	把 q/k 的相邻两维按位置旋转	编码**相对**位置、可外推、无额外参数	外推需插值/NTK 调整
ALiBi	注意力分数按距离加线性负 bias	外推好、实现极简、无参数	表达力略弱于 RoPE

RoPE 为什么能外推：因为 $q_m \cdot k_n$ 只依赖相对距离 $(m-n)$，所以理论上长度无关；但直接外推到远超训练的尺度会失真，所以实践要配位置内插（PI）、NTK-aware 缩放、YaRN。

多模态的扩展：图像/视频需要 2D/3D 位置（高、宽、时间），如 Qwen-VL 的 **M-RoPE**（把旋转维度分给 t/h/w）。

B42 ★★ attention 里的 mask 有哪几种？实现要注意什么？

A：三种：

1. **causal mask**（因果/自回归）：位置 i 只能看到 ⩽ i 的 key → 上三角置 $-\infty$。
2. **padding mask**：一个 batch 里不同的有效长度，key 侧的 pad 位置屏蔽。
3. **结构/跨模态 mask**：如视锥裁切（BEV query 看不到的相机）、跨样本隔离。

实现注意：- 用加性 mask（$scores + (-1e9 \text{ 或 } -inf)$）或 $masked_fill$，**统一语义**（True 是屏蔽还是保留，PyTorch 的 SDPA 里 bool mask 是 $True = 允许$，与 $masked_fill$ 相反）。- **一行全被屏蔽 → 分母为 0 → NaN**：要么保证每行至少一个有效位，要么对全屏蔽行单独处理。

B43 ★★ "置换等变"具体是什么意思？有什么后果？

A：设 P 是置换矩阵，则 $Attention(PX) = P \cdot Attention(X)$——**输入换顺序，输出只是跟着换顺序，内容不变**。

两个直接后果：1. **必须加位置编码**（否则模型分不清"猫追狗"和"狗追猫"）；2. **注意力的权重矩阵不含"距离"概念**（不像卷积的局部性）——所以它对"相邻"这件事没有先验，全靠学。

顺带一个面试题：为什么 Transformer 能表达卷积？→ 可以用特定的注意力模式（固定的相对位置偏置）模拟卷积核的行为，即"Transformer 的表达力包含卷积"。

B44 ★★ MQA / GQA / FlashAttention / 线性注意力 / Mamba 各解决什么？

A：

方法	解决什么	代价
MQA（Multi-Query）	所有头共享 1 组 K/V → KV cache ÷h	表达力略降
GQA（Grouped-Query）	h 个头分 g 组共享 K/V → ÷(h/g)	折中，主流选择
FlashAttention	分块 + 在线 softmax，不落 L^2 矩阵 → **省显存与 HBM 读写**	算法等价，不改 FLOPs
线性注意力（Performer/Linformer）	核近似/低秩 → **O(L) 复杂度**	近似误差、长程依赖略弱
Mamba / SSM	选择性状态空间 → 线性复杂度、推理 O(1) 每步	表达力待验证、生态不成熟

一句话："MQA/GQA 省的是**推理时的 KV cache**；FlashAttention 省的是**显存和带宽**；线性注意力/Mamba 改的是**复杂度阶**——三者解决的是不同层面的问题。"

B45 ★ self-attention 与 CNN / RNN 的本质区别?

A:

	CNN	RNN	Self-Attention
感受野	局部（靠堆叠扩大）	理论上全局（实际衰减）	**每层全局**
并行性	高	**低**（时序依赖）	高
归纳偏置	强（局部性、平移等变）	中（序列性）	**弱**（几乎无先验）
复杂度	$O(L \cdot k^2)$（与长度线性）	O(L)（串行）	**$O(L^2)$**
长依赖	需深层	梯度消失/爆炸	直接建模（但可能"注意力分散"）

取舍结论："**归纳偏置越强，小数据越好、大数据越受限**。CNN 在数据少时更强，Transformer 在数据够时上限更高——这也是 ViT 需要大数据/强增广/蒸馏才超过 CNN 的原因。"

B6 用代码验证原理（Python 语法不熟也能跑）

> 这一节的目的不是"实现算法"，而是**用几行代码把抽象结论变成看得见的数字**。 例如"softmax+CE 的梯度是 p−y"——写 5 行数值微分就能验出来，比背公式记得牢。
>
> 完整可运行文件： `ml_principles_verify.py` （47 项断言，全部实测通过），运行 `python3 ml_principles_verify.py` 。 下面每个片段都是那个文件里的精简版，**可以直接复制到 Python 里跑**。

B6.0 先补 12 个语法点（这一节只用得到这些）

你只写 C++ 的话，下面这些是"看得懂这段代码"的最小集：

#	语法	说明	等价 C++
1	`np.array([1,2,3])`	列表 → 数组	`vector<int>{1,2,3}`
2	`x.max(axis=-1, keepdims=True)`	沿最后一维取最大； `keepdims` 保住维度	手写循环 + 记录维度
3	`a * b` / `a / c`	**逐元素**运算，自动广播	循环逐元素
4	`y[mask]`	**布尔索引**：取出 mask 为 True 的元素	`if (mask[i]) v.push_back(...)`
5	`~mask`	布尔取反（**不是 `!`**）	`!mask`
6	`a[:, j]`	逗号左边是行、右边是列； `:` 表示全部	手写循环取第 j 列
7	`a[::-1]`	反向切片	`reverse`
8	`np.unique(a)`	去重并排序	`sort` + `erase(unique)`
9	`np.bincount(y)`	统计每个整数出现几次	`int cnt[k]={0}` 累加
10	`f"{x:.4f}"`	f-string 格式化， `.4f` 是 4 位小数	`printf("%.4f", x)`
11	`[... for x in xs]`	列表推导式	`for` + `push_back`
12	`np.allclose(a, b, atol=1e-6)`	浮点近似相等（**自检必用**）	`fabs(a-b)<eps`

一个提醒：Python 的 `=` 是**引用**， `b = a` 不会复制数组，要复制写 `b = a.copy()` 。这在本节里出现过好几次，是最容易踩的坑。

B6.1 验证 softmax 的三条结论

① 雅可比矩阵就是 $\mathrm{diag}(p) - p \cdot p^T$

```python
import numpy as np, math

def softmax(z):
    z = np.asarray(z, dtype=np.float64)        # ← 语法点：list 转数组
    z = z - z.max(keepdims=True)               # 减最大值（数值稳定，见下一条）
    e = np.exp(z)
    return e / e.sum(keepdims=True)

z = np.array([0.5, -0.2, 1.1])
p = softmax(z)

J_analytic = np.diag(p) - np.outer(p, p)       # ← 语法点：np.outer 求外积 → 3×3

eps = 1e-6
J_numeric = np.zeros((3, 3))
for j in range(3):                             # ← 语法点：range(3) = 0,1,2
    z2 = z.copy()                              # ← 语法点：必须 copy，否则改的是同一个数组
    z2[j] += eps
    J_numeric[:, j] = (softmax(z2) - p) / eps  # ← 语法点：[:, j] 取第 j 列

print(np.allclose(J_analytic, J_numeric, atol=1e-5))     # True
print(J_analytic.sum(axis=1))                            # [0, 0, 0]
```

跑出来的两件事：1. 解析雅可比与数值微分**完全一致** → 公式 $\partial p_i/\partial z_j = p_i(\delta_{ij} - p_j)$ 是对的；2. 雅可比**每行和为 0** → 这就是"输出必须和为 1，所以所有 logit 同加常数不变"的数学体现。

② 不减 max 会直接得到 nan

```python
z = np.array([1000.0, 1000.0, 1000.0])
naive = np.exp(z) / np.exp(z).sum()     # RuntimeWarning: overflow → nan
safe  = softmax(z)                       # [1/3, 1/3, 1/3]
```

观察：`np.exp(1000)` 超 float64 上限 → `inf`，`inf/inf = nan`。减 max 后最大项是 `exp(0)=1`，永不溢出。

③ 交叉熵的梯度就是 $p - y$

```python
z = np.array([0.3, 1.2, -0.7]); y = 1

def loss(z):
    return -math.log(softmax(z)[y])        # ← 语法点：函数里可以直接用外部变量 y

p = softmax(z)
grad_analytic = p.copy(); grad_analytic[y] -= 1          # ← p − y

eps = 1e-6
grad_numeric = np.zeros(3)
for i in range(3):
    zp, zm = z.copy(), z.copy()
    zp[i] += eps; zm[i] -= eps
    grad_numeric[i] = (loss(zp) - loss(zm)) / (2 * eps)   # 中心差分

print(np.allclose(grad_analytic, grad_numeric, atol=1e-6))   # True
```

这就是"框架为什么把 softmax 和 CE 合成一个算子"的实证：两者的雅可比精确抵消，$p - y$ 既简单又不饱和。

顺带两个小验证（一行代码的结论）

```python
# 温度：T 越大分布越平
for T in (0.5, 1.0, 3.0):
    print(T, np.round(softmax(z / T), 4))

# 二分类时 softmax([z,0]) == sigmoid(z)
print(softmax([1.7, 0.0])[0], 1 / (1 + math.exp(-1.7)))    # 0.8455 0.8455
```

B6.2 验证信息熵的四条结论

① 链式法则：`H(X,Y) = H(X) + H(Y|X)`

```
def entropy(p):
    p = np.asarray(p, dtype=np.float64)
    p = p[p > 0]                              # ← 语法点：布尔索引筛掉 0（0 · log0 记为 0）
    return -(p * np.log(p)).sum()

Pxy = np.array([[0.20, 0.05, 0.00],
                [0.05, 0.30, 0.05],
                [0.00, 0.05, 0.30]])
Px = Pxy.sum(axis=1)                          # 按行求和 = X 的边缘分布
Hxy = entropy(Pxy.ravel())                    # ← 语法点：ravel 把矩阵摊平
Hx = entropy(Px)
Hy_given_x = sum(Px[i] * entropy(Pxy[i] / Px[i]) for i in range(3))
#            ^ ↑ 语法点：生成器表达式放进 sum()，等价于一个 for 循环累加
print(abs(Hxy - (Hx + Hy_given_x)) < 1e-12)   # True
```

为什么值得跑一遍：条件熵的定义式 `H(Y|X) = Σ_x p(x)·H(Y|X=x)` 里"**每一项都要先归一化**（`Pxy[i] / Px[i]`）"这个细节，光看公式容易漏；跑一次就记住了。

② KL 散度非对称

```
P = np.array([0.5, 0.5])
Q = np.array([0.9, 0.1])

def kl(a, b):
    m = a > 0
    return float((a[m] * np.log(a[m] / b[m])).sum())

print(kl(P, Q), kl(Q, P))      # 0.5108  1.2451  ← 差别很大
```

观察到的两个数：`KL(P||Q)≈0.51`、`KL(Q||P)≈1.25`——这直接说明它**不是距离**（不满足对称性），也解释了变分推断里"前向 KL 会让 Q 摊平覆盖 P 的所有峰，反向 KL 会塌到某个峰"。

③ 交叉熵 = 熵 + KL

```
ce = -float((P * np.log(Q)).sum())
h  = entropy(P)
kl_v = float((P * np.log(P / Q)).sum())
print(abs(ce - (h + kl_v)) < 1e-12)     # True
```

结论：分类时 `H(P)` 是常数，所以**最小化交叉熵 ≡ 最小化 KL 散度**——这就是"为什么用交叉熵而不是直接算 KL"（省掉算 H(P)）。

④ 信息增益偏向多值特征（最重要的实验）

```
y = np.array([1, 1, 1, 0, 0, 0])          # 3 正 3 负
A = np.array([0, 0, 0, 1, 1, 1])          # 好特征：2 个取值，每类纯
ID = np.arange(6)                          # 坏特征：每个样本一个取值

def cond_entropy(feat, y):
    total = 0.0
    for v in np.unique(feat):              # ← 语法点：np.unique 去重
        mask = feat == v
        w = mask.sum() / len(feat)
        total += w * entropy(np.bincount(y[mask], minlength=2) / mask.sum())
    return total

H_parent = entropy([0.5, 0.5])                      # 0.6931
gain_A  = H_parent - cond_entropy(A,  y)            # 0.6931  ← 完全分开
gain_ID = H_parent - cond_entropy(ID, y)            # 0.6931  ← 也"完全分开"!
```

这就是 ID3 缺陷的现场证据：用"样本 ID"这种毫无泛化能力的特征，信息增益同样是最大的。接着验证增益率能区分它们：

```
def iv(feat):
    return entropy(np.array([(feat == v).sum() / len(feat) for v in np.unique(feat)]))

print(gain_A / iv(A), gain_ID / iv(ID))    # 1.0000   0.3869
```

结论：增益率把 ID 号特征从 1.0 压到 0.387——因为它的"分裂信息 IV"更大（6 个取值 vs 2 个取值）。

B6.3 验证分类树的两条结论

① 手写 CART 能拟合到 100%（用来确认实现没错）

```
def gini_counts(y, K):
    p = np.bincount(y, minlength=K) / len(y)      # ← 语法点：bincount 统计每类次数
    return 1.0 - (p ** 2).sum()

def build_tree(X, y, depth=0, max_depth=4, min_leaf=2):
    node = {"label": int(np.bincount(y, minlength=2).argmax())}   # ← 用 dict 当节点
    if depth >= max_depth or len(np.unique(y)) == 1 or len(y) < 2 * min_leaf:
        return node
    best = (1e-9, None)
    parent = gini_counts(y, 2)
    for f in range(X.shape[1]):
        vals = np.unique(X[:, f])
        for t in (vals[:-1] + vals[1:]) / 2:       # ← 候选阈值 = 相邻中点
            m = X[:, f] <= t
            if m.sum() < min_leaf or (~m).sum() < min_leaf:
                continue
            g = parent - (m.sum() * gini_counts(y[m], 2)
                          + (~m).sum() * gini_counts(y[~m], 2)) / len(y)
            if g > best[0]:
                best = (g, (f, t, m))
    if best[1] is None:
        return node
    f, t, m = best[1]
    node.update({"feat": f, "thr": float(t),
                 "left":  build_tree(X[m],  y[m],  depth + 1, max_depth, min_leaf),
                 "right": build_tree(X[~m], y[~m], depth + 1, max_depth, min_leaf)})
    return node
```

注意三个 Python 语法点：- `{"label": ...}` 用**字典**表示节点——Python 没有指针，字典/对象都是"引用传递"，所以 `node["left"] = build_tree(...)` 天然就能建树（等价于 C++ 的 `node->left = ...`，但不用管内存）。- `~m` 是布尔取反（`!` 在 numpy 里不适用）。- `vals[:-1] + vals[1:]` 这个切片加法一次就得到所有相邻对，C++ 里要显式循环。

实测：两簇数据训练集准确率 **1.000**，根节点阈值切在两簇之间。

② 连续特征的候选阈值只有 n−1 个

```
col = np.array([0.1, 0.5, 0.5, 0.9, 1.7])
vals = np.unique(col)                    # [0.1, 0.5, 0.9, 1.7] —— 5 个点去重成 4 个
thrs = (vals[:-1] + vals[1:]) / 2        # [0.3, 0.7, 1.3] —— 3 个候选
print(len(thrs) == len(vals) - 1)        # True
```

说明：原始 5 个样本、去重后 4 个不同值 → 只有 **3 个有效候选阈值**。两个 0.5 之间切不开，任何落在同一区间的阈值划分结果完全相同。

B6.4 验证 K-Means 的三条结论

① inertia 单调不增（收敛性的证据）

```
def kmeans_simple(X, k, iters=50, seed=0, record=False):
    rng = np.random.default_rng(seed)                    # ← 语法点：新式随机数生成器
    C = X[rng.choice(len(X), k, replace=False)].copy()   # ← 选 k 个不同下标
    hist = []
    for _ in range(iters):                               # ← 语法点：_ 表示"用不到的循环变量"
        d = ((X[:, None, :] - C[None, :, :]) ** 2).sum(-1)   # [N,k] 距离平方（广播）
        lab = d.argmin(1)                                # 每行最小值的下标
        for j in range(k):
            m = lab == j
            if m.any():                                  # ← 语法点：.any() 有 True 就 True
                C[j] = X[m].mean(0)                      # 布尔索引取子集再求均值
        hist.append(((X - C[lab]) ** 2).sum())           # C[lab] = 按标签取中心
    return lab, C, hist
```

实测输出：首轮 inertia ≈ 890 → 末轮 ≈ 98，**每轮都不增**（`np.diff(hist) <= 0` 全为真）。这就是 B30 说的"E 步和 M 步都不会增大目标函数"的实证。

② 局部最优：20 个种子差 55 倍

```
inertias = [kmeans_simple(X3, 3, seed=s)[2][-1] for s in range(20)]
inertias = sorted(inertias)
print(f"min={inertias[0]:.1f} 中位={inertias[10]:.1f} max={inertias[-1]:.1f}")
```

实测：`min=22.7 / 中位=22.7 / max=1247.2`——最差的种子比最好的**差 55 倍**，因为它把两个真实簇合并、另一个簇劈开了。

这句话可以直接讲给面试官："同一份数据、同一个算法，只换初始化，inertia 能差两个数量级——所以 `n_init` 或 k-means++ 不是优化项，是必需品。"

③ 球形假设失效：同心环上完全分不开

```
t = np.linspace(0, 2 * math.pi, 100, endpoint=False)     # ← 语法点：等距数列
ring1 = np.column_stack([np.cos(t), np.sin(t)]) * 1.0     # ← 按列拼成 (100,2)
ring2 = np.column_stack([np.cos(t), np.sin(t)]) * 3.0
X = np.vstack([ring1, ring2])                             # ← 语法点：vstack 竖着拼
```

实测：kmeans(k=2) 在同心环上的"按环划分纯度"只有 **100/200**（等于完全没分开：每个簇里两个环各占一半）。这就验证了"kmeans 只能找凸的、球形的簇"——这种数据该用 DBSCAN 或谱聚类。

顺带实测了 k 的选择：

k	inertia	轮廓系数均值
1	887.8	—
2	**98.3**	**0.778**
3	81.4	0.548
4	68.3	0.566

读法：inertia 从 k=1 到 k=2 掉了一大截（887→98），之后平缓 → **肘部在 k=2**；轮廓系数也在 k=2 最高。两种方法给出同一答案，这才是可信的 k。

B6.5 验证自注意力的四条结论

① 手算 attention，打印每个中间量

```
def attention_manual(X, Wq, Wk, Wv, mask=None):
    Q, K, V = X @ Wq, X @ Wk, X @ Wv          # ← @ 就是矩阵乘
    dk = Q.shape[-1]                          # 最后一维长度
    S = Q @ K.T / math.sqrt(dk)               # [L,L] 相似度
    if mask is not None:
        S = np.where(mask, -1e9, S)           # ← 逐元素三目
    A = softmax(S)                            # 逐行归一化
    return A @ V, A
```

取 `X=[[1,0],[0,1],[1,1]]`、权重为单位阵，实测中间量：

```
Q·Kᵀ     = [[1, 0, 1],        scores = Q·Kᵀ/√2 = [[0.707, 0,    0.707],
            [0, 1, 1],                            [0,     0.707,0.707],
            [1, 1, 2]]                            [0.707, 0.707,1.414]]
attn     = [[0.4011, 0.1978, 0.4011],   行和 = [1, 1, 1]
            [0.1978, 0.4011, 0.4011],
            [0.2483, 0.2483, 0.5035]]
```

看懂这张表：第 3 行（token 是 [1,1]）和所有 token 的相似度都高，所以注意力更"平均"；第 1、2 行各自只跟自己像，于是对角权重最大。**这就是"注意力按相关性分配"的直观样子**。

② 为什么除以 √dk：实测标准差

```
for dk in (8, 64, 256):
    q = rng.normal(size=(2000, dk)); k = rng.normal(size=(2000, dk))
    dots = (q * k).sum(1)                    # 逐行点积
    print(dk, dots.std(), (dots / math.sqrt(dk)).std())
```

实测：

dk	未缩放 std	缩放后 std
8	2.76（≈√8=2.83）	0.98
64	7.94（≈√64=8）	0.99
256	16.15（≈√256=16）	1.01

这就是 B38 方差论证的实证：`Var[q·k] = d_k`、`std = √d_k`；除以 √dk 后所有维度的 scores 都回到 std≈1，softmax 不会饱和。**面试时能报出这三个数字，比只背公式强得多。**

③ 置换等变：打乱输入，输出同序打乱

```
out,      _ = attention_manual(X, W, W, W)
perm = np.array([2, 0, 3, 1])                # ← 语法点：用数组当下标做重排
out_perm, _ = attention_manual(X[perm], W, W, W)
print(np.allclose(out_perm, out[perm]))       # True
```

结论：attention 对输入顺序**完全无感**——所以必须加位置编码（B41）。这是"为什么非要 RoPE/正弦编码"的最硬证据。

④ 因果 mask 的实际权重矩阵

```
mask = np.triu(np.ones((4, 4), dtype=bool), k=1)   # ← 语法点：np.triu 取上三角
```

实测输出：

```
attn = [[1.000, 0.000, 0.000, 0.000],
        [0.001, 0.999, 0.000, 0.000],
        [0.109, 0.651, 0.240, 0.000],
        [0.080, 0.517, 0.172, 0.231]]     每行和都 = 1
```

读法：上三角全 0（看不到未来），下三角按相关性分配；每行仍然和为 1（归一化只在可见范围内做）。顺便能看到"越靠后的 token 分给第一个 token 的权重越小"，这是因为 softmax 重新归一化后的自然结果。

B6.6 这一节能给你什么（面试用法）

1. **被问"你怎么确认自己理解对了"**：答"我习惯用数值微分/小数据把公式跑出来验证，比如 softmax 的雅可比我用数值微分对过，交叉熵的梯度确实是 p−y"。
2. **被问"为什么除 √dk"**：直接报实测——"dk 从 8 到 256，点积标准差从 2.76 涨到 16.15，正好是 √dk"。
3. **被问"kmeans 为什么只是局部最优"**：报"同一数据 20 个初始化，inertia 从 22.7 到 1247，差 55 倍"。
4. **被问"信息增益有什么问题"**：现场写三行——用 ID 号特征算出和信息增益一样大的结果，再报增益率把它从 1.0 压到 0.387。

这四句话的共同点：都是"我跑过"而不是"我记得"。

Part C 图像处理与卷积网络

> 这一部分补 CV 基本功：**Part C1 图像处理**（C1–C12）→ **C2 CNN 组件与计算**（C13–C26）→ **C3 架构演进**（C27–C36）→ **C4 训练调优**（C37–C44）→ **C5 指标与损失**（C45–C50）→ **C6 与传统/多模态的接口**（C51–C54）。 特点：**凡是能算的都给出算式和具体数字**，面试时现场算一遍比背结论有说服力。

C1 图像处理基础（C1–C12）

C1 ★★ 一张图像在计算机里怎么表示？常见色彩空间各适合什么？

A：表示：`H×W×C` 的张量，`dtype` 常为 uint8（0–255）或 float32（归一化到 0–1 或 z-score）。

色彩空间	含义	适合什么
RGB	红绿蓝加色	显示、深度学习默认输入（但三通道高度相关）
HSV / HSL	色相、饱和度、明度	**颜色分割、颜色增广**（改色相不影响亮度）
YUV / YCbCr	亮度 + 两路色度	**视频编码/压缩**（人眼对亮度更敏感，色度可下采样 4:2:0）
Lab / CIELAB	接近人眼感知均匀	颜色差计算（ΔE）、跨光照的稳定性
灰度	单通道亮度	边缘/纹理/OCR 预处理

面试考点：为什么视频压缩用 YUV？→ 因为可以**对色度下采样**（4:2:0 直接省 50% 数据）而人眼几乎无感，RGB 做不到这一点（三通道同等重要）。

C2 ★★★ resize 用了什么插值？对下游有什么影响？

A：三种主流插值：

方法	做法	特点
最近邻	取最近的源像素	最快、无新值；**放大有锯齿，缩小会丢信息（欠采样别名）**
双线性	4 邻域加权（按距离）	快、平滑；**缩小会模糊**（相当于低通）
双三次	16 邻域（三次核）	质量最好、边缘更锐；稍慢

工程要点（面试常问）： - **缩小图像要先抗锯齿**（area 插值或先高斯模糊再采样），否则出现摩尔纹/别名—— `cv2.INTER_AREA` 就是干这个的。 - **深度学习里 resize 用双线性居多**（与 backbone 的平滑性匹配），**语义分割最好用双线性/双三次**（最近邻会让 mask 边界错位）。 - **全卷积网络对分辨率敏感**：训练用 512、测试用 1024 会掉点，因为感受野/统计量变了。

C3 ★★★ 常见的图像滤波有哪些？各自适合去什么噪声？

A：

滤波器	原理	适合	代价/缺点
均值滤波	邻域平均	高斯噪声	边缘模糊严重
高斯滤波	按距离加权（σ 控制平滑度）	高斯噪声、平滑	边缘也糊；σ 越大越糊
中值滤波	邻域中位数	**椒盐噪声**（脉冲噪声）	慢（要排序）、对高斯噪声一般
双边滤波	空间距离 × **灰度差**加权	保边去噪	慢（非可分离）、对强噪声无解
引导滤波	用引导图（如原图）做局部线性模型	保边、可做**边缘保持上采样**	需要引导图
非局部均值（NLM）	按图像块相似度加权	强去噪、纹理保留好	很慢

面试加分：**为什么高斯核可分离？** → $G(x,y) = G(x)\cdot G(y)$，二维卷积可拆成两次一维卷积，计算量从 K^2 降到 $2K$（K=7 时从 49 次乘加到 14 次）。

3σ 原则：高斯核半径通常取 3σ，超出部分的权重 < 0.3%，可以截断。

C4 ★★★ Canny 边缘检测的四步是什么？为什么需要非极大值抑制？

A：四步：

1. **高斯平滑**（去噪，避免噪声被误判成边缘）；
2. **计算梯度**（Sobel 算 gx、gy → 幅值 $\sqrt{(gx^2+gy^2)}$ 和方向 $\text{atan2}(gy,gx)$）；
3. **非极大值抑制（NMS）**：沿**梯度方向**看相邻两个像素，只有当前点幅值最大才保留 → 把"粗边缘"细化成**单像素宽**；

4. **双阈值 + 滞后连接**：高阈值确定"强边缘"，低阈值给出"弱边缘"候选，只保留与强边缘**连通**的弱边缘 → 抑制孤立噪声点，同时保住边缘的连续性。

为什么需要 NMS：梯度幅值在边缘附近是一个"脊"（几个像素宽都很大），不抑制就会得到粗边缘、后续做轮廓/直线拟合会重复计数。

追问：双阈值的两个值怎么定？→ 经验是高:低 ≈ 2:1 或 3:1；也有自适应方法（按梯度幅值分位数）。

C5 ★★ 直方图均衡化 / CLAHE 在做什么？为什么工业上常用 CLAHE？

A：**直方图均衡**把灰度分布映射成近似均匀分布（累积分布函数 CDF 作为映射函数），从而**提升对比度**。

问题：全局均衡会**过度放大平坦区域的噪声**（比如大片天空的细微噪声被拉到可见），且图中有强亮/暗区时局部仍然看不清。

CLAHE（限制对比度的自适应直方图均衡）：把图分块（如 8×8）各自均衡，并用 `clipLimit` **截断直方图的峰值**（超出部分均匀分回），再做块间**双线性插值**消除块边界。

为什么工业界爱用：夜间/逆光/雨雾场景下能显著提升视觉可见性，且参数少、可复现、无学习成本。**我们做低光照预处理时它就是首选基线**。

C6 ★★ 相机畸变怎么建模和校正？

A：两类畸变：

```
径向畸变（镜头形状）：  x_d = x(1 + k1·r² + k2·r⁴ + k3·r⁶),   r² = x²+y²
切向畸变（装配不平行）：  x_d = x + [2·p1·x·y + p2·(r²+2x²)],  y 方向对称
```

- k1 < 0 通常是**桶形**（广角/鱼眼），k1 > 0 是**枕形**。
- 校正：用内参 K（fx, fy, cx, cy）+ 畸变系数（k1,k2,p1,p2,k3），通过 `undistort` 反算 → 实际实现是**反向映射 + 插值**（因为正向映射会有空洞）。
- **鱼眼**要用专门的模型（等距投影 `r = f·θ`），普通针孔模型拟合不了。

面试加分：畸变系数怎么标定？→ 张正友标定法（多张棋盘格，用单应性求解内参初值，再非线性优化最小化重投影误差）；评估标准是**重投影误差**（RMS，好的标定 < 0.5 px）。

C7 ★★ 仿射变换和透视变换的区别？怎么求变换矩阵？

A：

	仿射（Affine）	**透视（Homography）**
自由度	**6**（保持平行性）	**8**（平行线可交于消失点）
矩阵	2×3（最后一行 [0,0,1]）	3×3（差一个尺度，8 自由度）
需要点对	**3 对**不共线点	**4 对**（任意三点不共线）
用途	旋转/缩放/平移/剪切	车道线 BEV、文档矫正、平面单应

求解：把对应点代入方程得到线性方程组，用 **DLT（直接线性变换）** 求最小二乘解（4 对点以上用 SVD），再用 RANSAC 剔除外点。

追问：为什么 BEV 变换常用单应而不是仿射？→ 因为相机是斜视地面的（透视投影），仿射保持不了"近大远小"，只有地面**平面**的单应才是精确的——**这也是为什么单应只对地面平面前提成立**（非平面区域会被拉变形）。

C8 ★★ 图像金字塔有什么用？拉普拉斯金字塔在做什么？

A：- **高斯金字塔**：逐层高斯模糊 + 下采样（每层尺寸减半），用于多尺度检测、特征匹配（SIFT 的尺度空间）。 - **拉普拉斯金字塔**：`L_i = G_i − upsample(G_{i+1})`，即"本层减去上层的上采样"，保存的是**各频段的细节**。 - **用途**：图像融合（把两张图的不同频段拼接，如多曝光融合/多聚焦融合）、图像压缩、超分。

为什么有用：不同尺度关注的语义不同（低分辨率看整体、高分辨率看细节），检测里的 FPN、分割里的多尺度特征都是这个思想的延伸。

C9 ★★ PSNR / SSIM / LPIPS 分别在衡量什么?

A:

```
MSE  = (1/N)Σ(I − K)²
PSNR = 10 · log10(MAX² / MSE)        (dB，越大越好；但与人眼感知相关性弱)
SSIM = (2μxμy + C1)(2σxy + C2) / [(μx²+μy²+C1)(σx²+σy²+C2)]    (结构相似性，[−1,1])
```

- **PSNR** 只看逐像素误差，对"整体亮度偏移"极敏感、对"结构错乱"不敏感 → 常出现 PSNR 高但肉眼更差的情况。
- **SSIM** 从**亮度、对比度、结构**三项比较，更贴近人眼（局部窗口计算后取均值）。
- **LPIPS** 用预训练网络（VGG/AlexNet）的**深层特征距离**，与人类判断相关性最高，是现在超分/生成的默认指标。

面试话术："指标要和任务匹配：去噪看 PSNR/SSIM，超分/生成看 LPIPS + 感知质量，检测分割还是看任务的 IoU/mAP。"

C10 ★ 形态学操作有哪些？各自的作用?

A：四个基本操作：

操作	定义	作用
腐蚀	结构元覆盖区域内**取最小**	缩小前景、断开细连接、去小噪点
膨胀	取**最大**	扩大前景、填补小孔
开运算	先腐蚀后膨胀	**去小噪点/毛刺**，面积不变
闭运算	先膨胀后腐蚀	**填小孔/缝隙**，面积不变

进阶：顶帽（`原图 − 开运算`，提取小亮目标）、黑帽（`闭运算 − 原图`，提取小暗目标）、形态学梯度（`膨胀 − 腐蚀`，粗边缘）。

用途：二值 mask 的后处理（去孤立点、填洞）、OCR 字符粘连分离、工业缺陷检测的预处理。

C11 ★★ 图像数据增广有哪些？哪些任务不能用?

A：按类型：

- **几何**：翻转、随机裁剪、旋转、缩放、仿射/透视扰动。
- **颜色**：亮度/对比度/饱和度抖动、色调偏移、gamma、JPEG 压缩、模糊、噪声。
- **遮挡/混合**：Random Erasing、Cutout、**Mixup**（两张图线性混合 + 标签混合）、**CutMix**（贴一块区域 + 标签按面积混合）。
- **策略搜索**：AutoAugment、**RandAugment**（随机选 N 种变换 + 统一强度 M，超参只有两个）。
- **多尺度**：随机分辨率训练（尺度抖动）。

哪些不能用（面试高频）：- **OCR/文档**：颜色抖动、翻转、强裁剪都会破坏语义（文字方向、颜色对含义有影响）。- **检测/分割**：裁剪后必须**同步变换标签**（框/掩码），否则标签错位。- **VLM 指令微调**：增广会让"描述内容"与图不一致（颜色变了但 caption 没变），**制造假监督**。- **医学/工业**：翻转可能违反解剖/工艺先验（左右心、螺纹方向）。

C12 ★ 频域方法（傅里叶/小波）在图像里有什么用?

A：三条实际用途：

1. **滤波设计**：频域里做理想/巴特沃斯低通（但会振铃），高斯低通无振铃（因为高斯是自傅里叶变换）。
2. **周期性噪声去除**：在频谱图上找到亮点（周期噪声的频点）挖掉，再逆变换——纺织/扫描件的经典手法。
3. **小波**：多分辨率分解（低频近似 + 高频细节），用于图像压缩（JPEG2000）、去噪（小波阈值）、医学融合。

深度学习里的对应：频域卷积（FFT 加速大核卷积）、频域域适应（把低频（风格）与高频（结构）分离做风格迁移/域泛化）。

C2 CNN 组件与计算（C13–C26）

C13 ★★★ 卷积的输出尺寸怎么算？给一个具体例子。

A：

```
O = floor( (I + 2P − K) / S ) + 1
```

（I 输入边长、P padding、K 核大小、S 步长）

带空洞卷积时：`K_eff = D·(K−1) + 1`，再代入上式。

例子（面试常现场问）：- 输入 224，K=7，S=2，P=3 → `(224 + 6 − 7)/2 + 1 = 112`（这正是 ResNet 的 stem：7×7/s2 → 再 maxpool 3×3/s2 → 56） - 输入 56，K=3，S=2，P=1 → `(56 + 2 − 3)/2 + 1 = 28`（降一半） - 输入 32，K=3，S=1，P=0 → `30`（**same 尺寸必须 P=(K−1)/2，K 为奇数**）

追问：为什么核大小通常是奇数？→ ① 有中心像素（便于定义"以谁为中心"）；② same padding 时 `P=(K−1)/2` 是整数。

C14 ★★★ 感受野怎么算？三个 3×3 堆叠等于一个 7×7 吗？

A：递推公式（从浅到深）：

```
RF_l = RF_{l−1} + (K_l − 1) · Π_{i<l} S_i        初值 RF_0 = 1
```

三个 3×3（stride 1）：`1 → 1+2=3 → 3+2·1=5 → 5+2·1=7` → **感受野 7，等于一个 7×7**。

但不等价于一个 7×7 卷积：

	3 个 3×3	1 个 7×7
感受野	7	7
参数	$3·(9C^2) = 27C^2$	$49C^2$
非线性	**3 层**（表达能力更强）	1 层
计算量	$3·9HWC^2$	$49HWC^2$

结论："感受野相同，但堆叠版的**参数只有 55%、非线性多两层**——这就是 VGG 全用 3×3 的原因。"

追问：有效感受野（ERF）是什么？→ 理论感受野内每个像素的贡献并不均等，实际"起作用"的区域是**高斯状**的，中心大、边缘小（可用梯度/扰动实验测）。**所以理论感受野 7 不代表边缘信息真被用上了**。

C15 ★★★ 参数量和 FLOPs 怎么算？举一个对比。

A：

```
标准卷积参数 = (Cin · K · K + 1) · Cout          (+1 是 bias)
标准卷积 FLOPs（近似 MACs）= H_out · W_out · Cin · K · K · Cout
```

具体例子（Cin=Cout=256, K=3, H=W=56）：

	参数	MACs
标准卷积	`(256·9+1)·256 = 589,824`	`56·56·256·9·256 ≈ 1.85 G`
深度可分离（DW+PW）	`256·9 + 256·256 = 67,840`（**约 1/8.7**）	`56·56·(256·9 + 256·256) ≈ 0.21 G`（**约 1/8.7**）

深度可分离卷积 = 逐通道卷积（每个通道一个 K×K，输出通道数不变）+ 逐点卷积（1×1，跨通道混合）：

```
参数 = Cin · K · K + Cin · Cout        压缩比 ≈ 1/Cout + 1/K²
```

面试提醒：报"参数量"和"FLOPs"要区分**是否含 bias、是否算乘加为 2 次**（有的论文算 2×MACs），否则数字对不上。

C16 ★★★ 1×1 卷积有什么用？为什么它能"降维"？

A：四个作用：

1. **跨通道信息融合**：本质是"在通道维度做全连接"（每个位置独立的线性组合）。
2. **降维/升维**：把 C 通道变成 C'，`参数 = C·C'`，极便宜。ResNet 的 bottleneck（256→64→64→256）就是靠它把计算量压到 1/4~1/8。
3. **改变通道数而不改空间尺寸**：投影到目标维度。
4. **加非线性**：1×1 conv + ReLU 等价于"逐位置的两层 MLP"。

为什么能降维：它不聚合邻域信息（K=1），只在通道方向做线性映射，所以是"通道上的矩阵乘"。

面试延伸：ViT 里的 patch embedding 也是用 `K=patch_size, S=patch_size` 的卷积实现的（等价于切块 + 线性投影）。

C17 ★★ 池化 vs 步长卷积，怎么选？

A：

	最大池化	平均池化	步长卷积
作用	保留最强响应、扩大感受野	平滑、保留整体能量	降采样 + **可学习**
优点	无参数、对位置小变化鲁棒	无参数、梯度均匀	学得到更好的下采样方式
缺点	丢位置信息、梯度只在最大处	弱响应被平均掉	有参数、可能引入棋盘/混叠

趋势：现代架构（ResNet-D、MobileNet、ConvNeXt）**更倾向步长卷积或 avgpool + 1×1**，因为 maxpool 丢掉的信息无法恢复；而"下采样要配合抗混叠（anti-aliasing）"（BlurPool）也是常考点。

C18 ★★★ BN / LN / IN / GN 的区别？CV 里为什么默认 BN？

A：

归一化	统计量的维度	依赖 batch?	场景
BN	每个通道，跨 (N, H, W)	**是**	CNN 标配（大 batch）
LN	每个样本，跨 (C, H, W)	否	Transformer / RNN
IN	每个样本每个通道，(H, W)	否	风格迁移（抹掉逐图风格差异）
GN	每个样本分成 G 组，组内 (C/G,H,W)	否	**小 batch 检测/分割**（BN 失效时的替代）

> BN: $y = \gamma \cdot (x - \mu_B)/\sqrt{(\sigma_B^2 + \varepsilon)} + \beta$　　训练用 batch 统计量，推理用滑动平均

CV 里默认 BN 的原因：卷积核共享 → 同一通道的统计量在空间上稳定，跨 batch 估计更可靠；同时 BN 平滑了损失曲面（允许更大学习率）。

BN 的坑（必答三个）：① **小 batch 时统计量噪声大**（检测/分割 batch=1~4 时掉点严重）；② **训练/推理不一致**（忘记切换 eval 模式 = 经典 bug）；③ **分布差异大的任务**（多域、风格差异）统计量不匹配 → 用 GN/LN 或 AdaBN。

C19 ★★★ 激活函数怎么演进？为什么 ReLU 取代了 sigmoid？

A：

激活	特点	问题
sigmoid / tanh	平滑、有界	**两端饱和 → 梯度消失**（导数最大仅 0.25）
ReLU `max(0,x)`	正区间梯度恒 1、计算极快、稀疏激活	**死亡 ReLU**（负区间梯度 0，学习率大时神经元永久失活）
LeakyReLU / PReLU	负区间给一个小斜率（可学习）	多一个超参
ELU / SELU	负区间平滑趋近 −1	含 exp，稍慢
GELU	`x·Φ(x)`（高斯 CDF 加权）	稍慢；Transformer/ViT 默认

激活	特点	问题
SiLU / Swish	`x · σ(x)`	主流大模型常用（平滑、非单调）

ReLU 取代 sigmoid 的三个原因：① 正区间**梯度不衰减**（解决深层网络梯度消失）；② 计算只有一次比较（比 exp 快得多）；③ 稀疏性（约一半神经元输出 0）→ 表征更解耦。

追问：SiLU/GELU 为什么更好？→ 在 0 附近**平滑且非单调**（有个小负值区），梯度更连续、对优化更友好；代价是计算量。

C20 ★★★ 残差连接为什么能缓解梯度消失？给个推导。

A：设残差块 `x_{l+1} = x_l + F(x_l)`，展开到第 L 层：

```
x_L = x_l + Σ_{i=l}^{L-1} F(x_i)
```

对 `x_l` 求导：

```
∂L_loss/∂x_l = ∂L_loss/∂x_L · ( 1 + ∂/∂x_l Σ F(x_i) )
```

关键在于那个 `1`：即使后面的 `∂F` 项因连乘而趋近 0，梯度仍能通过**恒等路径**无损回传。这是"梯度高速公路"。

附带好处：① 恒等映射让"加深至少不变差"成为可能（优化上的 ease）；② 特征复用/集成视角（ResNet 可看作多路径的隐式集成）。

追问：为什么是"加法"而不是"拼接"（DenseNet）？→ 加法**不增加通道数**（计算量恒定、可无限堆叠），拼接会增加通道数（后续层更贵，但特征复用更彻底）。

C21 ★★ 权重初始化怎么选？Xavier 和 He 的区别？

A：目标是**保持各层激活的方差稳定**（避免逐层放大/缩小）。

```
Xavier (Glorot) : Var(W) = 2/(n_in + n_out)      适合 tanh/sigmoid（对称激活）
He (Kaiming) :    Var(W) = 2/n_in                适合 ReLU（因为 ReLU 把一半激活置零，方差减半，所以要加倍）
```

推导思路：`Var(y) = n_in · Var(W) · Var(x)`，要 `Var(y)=Var(x)` 就得 `Var(W)=1/n_in`；ReLU 输出只保留一半方差 → 补一个 2 倍。

实践经验：① 现代框架的默认初始化基本可用；② **BN 存在时初始化就没那么敏感**（BN 会重新标准化）；③ 太小的初始化 → 信号逐层衰减；太大 → 爆炸。

C22 ★★ 反卷积（转置卷积）为什么会有棋盘格伪影？怎么避免？

A：转置卷积实现上采样时，输出像素被覆盖的次数**不均匀**（核重叠次数随位置变化），导致某些位置值偏大 → 网格状纹路。

四种避免方法：1. 用 `stride=1` 的卷积 + 前面的**插值上采样**（最常用、最稳，如 `upsample(bilinear) + conv3x3`）。 2. 用 `stride` 整除 `kernel`（如 S=2,K=4 或 S=2,K=2），让重叠均匀。 3. **Pixel Shuffle**（亚像素卷积）：先卷积出 $C \cdot r^2$ 通道，再 reshape 成高分辨率（无重叠问题，超分里常用）。 4. 用 resize + conv 替代（语义分割的常见做法）。

追问：转置卷积和"真反卷积"是一回事吗？→ **不是**。数学上的反卷积是卷积的逆运算；深度学习说的"反卷积"其实是**转置卷积**（梯度形式的卷积），不保证能还原输入。

C23 ★★ 空洞卷积的作用与副作用？怎么缓解？

A：**作用**：在不增加参数、不降分辨率的前提下**成倍扩大感受野**（`K_eff = D · (K−1)+1`），DeepLab 系列用它替代池化。

副作用（网格效应 / gridding）：连续堆叠相同 dilation 的空洞卷积时，**采样点只落在固定格点上**，中间像素永远不参与计算 → 小目标/细节信息被跳过。

缓解：① **混合 dilation**（如 1,2,5 交替，HDC 设计）；② 串联不同 dilation 的空洞空间金字塔（ASPP）；③ 与普通卷积/上采样混用。

面试加分："我们的多任务模型里用 ASPP 做粗尺度辅助头，本质就是用多个 dilation 覆盖不同感受野，让粗头的监督更全局——这个辅助头给了 0.2 的权重。"（**这条把 C23 和你的实际配置连起来了**）

C24 ★★ 为什么卷积有"平移等变性"，而它有局限？

A：卷积 + 池化带来**平移等变（translation equivariance）**：输入平移，输出跟着平移。这是极强先验，也是 CNN 数据效率高的原因。

局限（三个）： 1. **下采样破坏等变性**：stride/pooling 会让等变只在采样格点上成立（亚像素平移不保持），这就是"CNN 对小平移不够鲁棒"的原因之一。 2. **边界效应**：padding 让边缘位置的等变性不成立。 3. **全局等变 vs 位置敏感**：检测里"同一物体在不同位置应有不同输出"，所以需要位置编码/坐标监督来**打破**纯等变。

顺带：ViT 因为几乎没有这个先验，才需要海量数据；ConvNeXt 用大核 + LN + GELU 把架构现代化，证明"CNN 的归纳偏置仍有效"。

C25 ★★ 混合精度、channels_last、融合算子各优化什么？

A：

技术	优化什么	注意
AMP（fp16/bf16）	显存减半、TensorCore 提速	fp16 要 loss scaling（防下溢）；**bf16 不需要**（动态范围大，但精度低）
channels_last（NHWC）	访存连续性（GPU 上 NHWC 对 1×1 卷积/BN 更快）	与某些算子不兼容，需要全链路统一
融合算子（conv+BN+ReLU 折叠）	减少 kernel launch 与访存	推理时常见；**训练时 BN 统计量要小心**
梯度检查点	显存换时间（重算激活）	约 30% 时间代价
torch.compile / TensorRT	图优化 + 算子融合	动态 shape 支持有限

C26 ★★ 卷积和全连接的关系？为什么现代网络几乎不用大 FC 层？

A：**全连接是卷积的特例**（K = 输入尺寸、感受野覆盖全图）；反过来，把 FC 的权重 reshape 就是卷积核。

不用大 FC 的原因：① 参数量爆炸（`H·W·C → N` 的 FC 是灾难级参数，如 VGG 第一个 FC 就有 1 亿参数）；② 丢失空间结构（不做归纳偏置）；③ 不能处理变尺寸输入。

现代做法：**全局平均池化（GAP）+ 一层小 FC**（ResNet 的做法），参数量从亿级降到 `C·N`。

C3 经典架构演进（C27–C36）

C27 ★★★ 串一遍经典 CNN 的演进线，每一步解决了什么？

A：

模型	年份	关键贡献	解决的痛点
LeNet-5	1998	conv + pool + FC 的雏形	手写数字识别
AlexNet	2012	ReLU、Dropout、GPU 训练、数据增广	深网络能训起来了（sigmoid 饱和被 ReLU 解决）
VGG	2014	**全 3×3 堆叠**、模块化	证明"深度 + 小核"有效（参数量爆炸是代价）
GoogLeNet/ Inception	2014	**多尺度并行分支 + 1×1 降维 + GAP**	用宽度换深度、把参数从亿级降到 500 万
ResNet	2015	**残差连接 + BN + bottleneck**	解决深层退化（56 层比 20 层差）与梯度消失
DenseNet	2017	密集连接（每层接收前面所有层）	特征复用、参数更少；代价是显存
MobileNet/ ShuffleNet	2017-18	深度可分离、通道混洗	端侧算力约束

模型	年份	关键贡献	解决的痛点
EfficientNet	2019	**复合缩放**（深度/宽度/分辨率联合）	缩放策略从"拍脑袋"变"可搜索"
ConvNeXt	2022	把 Transformer 的设计（大核、LN、GELU、倒瓶颈）搬回 CNN	证明 CNN 的归纳偏置仍有价值

一句话串起来："AlexNet 证明能训深，VGG 证明深有效，Inception 证明要宽且省，ResNet 证明还能更深，后面的都在**效率**上做文章，ConvNeXt 是回头看'CNN 到底输在哪'。"

C28 ★★ Inception 模块的核心思想？为什么必须用 1×1 卷积？

A：**多尺度并行**：同一层输入同时过 1×1、3×3、5×5、maxpool 四条支路，再在通道维拼接 → 一个模块同时看不同感受野。

为什么必须 1×1 降维：如果直接对 256 通道做 5×5 卷积，参数是 $25 \cdot 256 \cdot 256 \approx 1.6M$；先用 1×1 把 256 降到 32 再 5×5，参数 $256 \cdot 32 + 25 \cdot 32 \cdot 32 \approx 34k$ ——**降了近 50 倍**。没有 1×1，这个模块根本装不下。

追问：Inception 和"多分支 ResNet（ResNeXt）"的区别？→ Inception 是**手工设计**的分支拓扑，ResNeXt 把分支变成**同构分组卷积**（组数可调），更规整、更好扩展。

C29 ★★★ ResNet 的 bottleneck 为什么是 1×1 → 3×3 → 1×1？

A：以 256→256 为例：

方案	参数量
直接 3×3：$9 \cdot 256 \cdot 256$	**589,824**
bottleneck：$1\times1\ 256\to64$ + $3\times3\ 64\to64$ + $1\times1\ 64\to256$	$16{,}384 + 36{,}864 + 16{,}384 = 69{,}632$（**约 1/8.5**）

逻辑：先用 1×1 **压缩通道**（降维）→ 在低维空间做 3×3（省算力）→ 再 1×1 **恢复通道**（升维）。这就是"bottleneck"命名的由来（中间窄、两头宽）。

深层设计原因：ResNet-50 之前用 basic block（两个 3×3），到 50 层以上必须用 bottleneck，否则算力下不来。

追问：为什么中间是 3×3 而不是更大的核？→ 3×3 是"最小的能同时感知上下左右"的核，且堆叠便宜（见 C14），是精度/效率的最优点。

C30 ★★ DenseNet 和 ResNet 的本质区别？

A：

	ResNet	DenseNet
连接	$x_{l+1} = x_l + F(x_l)$（**相加**）	$x_{l+1} = concat(x_l, F(x_l))$（**拼接**）
通道数	不变（可无限堆叠）	**线性增长**（第 l 层的输入通道 = $k_0 + k \cdot l$）
参数	普通	**更少**（因为每层只需输出很小的 k=32 通道）
显存	较低	**很高**（所有中间特征都要保存，供后续拼接）
特征复用	隐式（多路径集成视角）	**显式**（每层直接看到原始输入）

面试话术："ResNet 是加法式的恒等路径（省计算、能很深），DenseNet 是拼接式的全连接复用（参数效率高、但显存爆炸）。工业界主流是 ResNet 系，因为它好部署。"

C31 ★★★ 轻量化网络的三条路线？

A：

1. **减少卷积计算量**： - **MobileNet v1**：深度可分离卷积（DW + PW），算力降到约 1/8~1/9（见 C15）。 - **ShuffleNet**：分组卷积（group conv）省算力，但组间信息不流通 → **channel shuffle**（把通道打乱重排）恢复通信。 - **MobileNet v2**：**倒残差（inverted residual）**——先 1×1 升维 6 倍 → DW 3×3 → 1×1 降维，配 **线性瓶颈**（最后一层不用 ReLU，防止低维信息被截断）。

2. **减少冗余分支/结构搜索**：NAS（MnasNet）、EfficientNet（复合缩放：深度 ∝ α^ϕ、宽度 ∝ β^ϕ、分辨率 ∝ γ^ϕ，约束 $\alpha\beta^2\gamma^2 \approx 2$）。
3. **蒸馏/量化/剪枝**：结构不变，靠训练与压缩技术。

面试加分："端侧我会先算三件事——**参数（内存）、MACs（算力）、访存（带宽）**。很多轻量模型参数量很小但仍快不起来，原因是逐层访存（depthwise 的访存效率低、GPU 上不友好）。"

C32 ★★★ SE 和 CBAM 各是什么？SE 为什么能提点还不贵？

A：

- **SE（Squeeze-and-Excitation）**：`GAP`（把 H×W 压成 1×1）→ `FC → ReLU → FC → sigmoid` 得到每通道一个权重 → **逐通道缩放**特征图。本质是**通道注意力**。
- **CBAM**：**通道注意力 + 空间注意力**串联（通道分支用 avg+max 双池化，空间分支用一个 7×7 卷积生成 H×W 的权重图）。

SE 便宜的原因：两个 FC 之间有降维比 r（通常 16），所以参数量只有 $2 \cdot C^2/r$（C=256, r=16 → 8k），相比卷积的 590k 可以忽略。而收益是稳定的（SE-ResNet50 在 ImageNet top-1 上约 +1 个点量级）。

追问：SE 和"注意力机制"（Transformer 的 attention）是一回事吗？→ 不同。SE 是**通道级重新加权**（软特征选择），没有 query-key 的成对建模；Transformer 的 attention 是**位置间的动态聚合**。**但思想的共同点是"用全局上下文来调制局部响应"**。

C33 ★★ FPN 为什么要"自顶向下 + 横向连接"？

A：目标检测的核心矛盾：**深层特征语义强但分辨率低**（定位粗），**浅层特征分辨率高但语义弱**（分类差）。FPN 用两条路把它们结合起来：

1. **自底向上**（backbone 的正常前向）：得到 P3/P4/P5 不同尺度的特征；
2. **横向连接**：每个层级用 1×1 卷积把通道数统一（如 256）；
3. **自顶向下**：把深层特征**上采样**后与同层横向特征**相加** → 浅层也获得强语义。

结果：每个尺度都有"高语义 + 高分辨率"，小目标检测显著提升。**这也是分割（DeepLab/UNet）共用的思想。**

C34 ★★★ 分割网络的三条技术路线（UNet / DeepLab / HRNet）？

A：

路线	代表	核心	强项	弱项
编码-解码 + 跳连	**UNet**、SegNet	下采样提语义、上采样恢复分辨率，**skip 把浅层细节直接送回去**	医学/小数据、边界精细	参数量大（UNet 对称结构）
空洞卷积保分辨率	**DeepLab v1/v2/v3+**	不做激进下采样，用空洞扩大感受野；**ASPP**（多 dilation 并行 + 全局池化）捕捉多尺度	大场景语义分割	高分辨率下显存/算力大、空洞网格效应
全程高分辨率	**HRNet**	不做"先降后升"，多分辨率分支**并行 + 反复融合**	关键点/姿态/精细分割	计算量高

面试一句话："UNet 靠跳连找回细节，DeepLab 靠空洞不丢分辨率，HRNet 干脆全程不降——本质都是在解决'语义与分辨率的矛盾'。"

追问：ASPP 和 SPP 什么关系？→ ASPP 是 SPP 的空洞版（用多个 dilation 的并行卷积替代多尺度池化），都为了多尺度上下文。

C35 ★★★ 卷积和 Transformer 的本质取舍？ConvNeXt 做了什么？

A：

	CNN	ViT
归纳偏置	**强**（局部性、平移等变、权重共享）	**弱**（几乎无先验）
数据效率	小数据也能训	**需要大数据/强增广/蒸馏**
长程依赖	需要堆叠扩大感受野	**每层全局**
计算	$O(HWC^2K^2)$，与分辨率线性	$O(N^2)$，与分辨率平方
高分辨率	友好	贵（需窗口/稀疏注意力）

ConvNeXt 的结论：把 ViT 的现代设计搬回纯 CNN（**7×7 depthwise 大核、LN 替代 BN、GELU、倒瓶颈、更少的激活/归一化层**、LayerScale），就能追平 Swin Transformer —— 说明**当年"Transformer 更强"有一部分其实是"训练技巧与结构细节"的差异**，不全是自注意力的功劳。

面试话术："我会按落地约束选：数据少/要端侧 → CNN 或混合；数据多/要长程建模 → ViT；实际大都是混合（CNN 提局部 + attention 提全局）。"

C36 ★ 多模态模型为什么偏爱 ViT，但这个选择有什么代价？

A：**偏爱 ViT 的原因**：① patch token 序列**天然适配 LLM 的 token 接口**（不需要额外的空间池化/展平策略）；② 全局注意力对"整图关系"建模更强（对描述/推理类任务友好）；③ 与 CLIP 系预训练权重配套（直接可用）。

代价（这是加分点）： 1. **密集预测弱**：ViT 的全局注意力会把空间细节"抹匀"，做分割/深度/占用时要额外加 positional 信息或多尺度结构——**这正是我做 3D 占用时的体会：纯 ViT 特征对细粒度几何不够，需要 FPN/多尺度头来补**。 2. **高分辨率贵**：$O(N^2)$，所以要靠窗口注意力或 token 压缩。 3. **小数据难训**：必须依赖大规模图文预训练。

C4 训练与调优（C37–C44）

C37 ★★★ 学习率策略有哪些？为什么需要 warmup？

A：四种主流：

策略	形状	适用
Step / MultiStep	阶梯下降（每 N 轮 ×0.1）	经典 CNN（ResNet 的标准配方）
Cosine 退火	余弦曲线平滑降到 0	现代默认，配合 warmup
One-Cycle	先线性升到峰值再降到很低	训练轮数固定时收敛最快
Plateau	指标不涨就降	不确定总轮数时

为什么需要 warmup：训练初期参数随机、梯度方向噪声大（尤其 BN 统计量还没稳定），直接用大学习率会导致**震荡甚至发散**；warmup 让学习率从很小逐步升到目标值，给 BN 统计量和早期表征一个"稳定期"。Transformer/ViT 尤其依赖 warmup。

追问：余弦退火为什么比 step 好？→ 平滑下降避免"降学习率时的指标抖动"，且后期小学习率有利于精细收敛；另外 cosine 的周期性重启（SGDR）能帮助跳出局部极小。

C38 ★★★ SGD 和 Adam 怎么选？为什么经典 CV 模型用 SGD？

A：

	SGD + Momentum	Adam / AdamW
更新	用一阶动量平滑梯度，**所有参数同一学习率**	一阶 + 二阶矩，**逐参数自适应步长**
收敛速度	慢（要精调 lr 与 schedule）	**快**（对 lr 不敏感、易上手）
泛化	通常**更好**（尤其中小数据、CNN）	常常略差（有"尖锐极小"倾向）
显存	小（只存动量）	大（存 m、v，约 3 倍参数显存）

经典 CV 用 SGD 的原因：① 大量实验表明同样的超参预算下 SGD+动量 的**最终泛化**更好；② Adam 的自适应步长在卷积网络上容易收敛到"尖锐"的解；③ 传统 pipeline（长训练 + cosine + 大 batch）已经和 SGD 调得很顺。

但现在：Transformer/ViT/大模型基本都用 **AdamW**（解耦 weight decay），因为 LN + 自适应优化更匹配。

C39 ★★★ AdamW 和 Adam 的区别？为什么 weight decay 要"解耦"？

A：**Adam 的实现里，L2 正则被加进梯度**，然后被自适应学习率缩放：$\theta \leftarrow \theta - lr \cdot (\hat{g} + \lambda\theta)/\sqrt{\hat{v}}$。结果是**梯度大的参数被正则得弱、梯度小的被正则得强**（因为除以 $\sqrt{v}$），与"均匀惩罚大权重"的初衷不符。

AdamW 解耦：$\theta \leftarrow \theta - lr \cdot \hat{g}/\sqrt{\hat{v}} - lr \cdot \lambda \cdot \theta$，正则项**不经过二阶矩缩放**，直接按 lr 衰减权重。

效果：同样的 λ 下正则更有效、更稳定；这是现在大模型训练的标准做法。

面试延伸：这也是为什么"Adam 上直接调 weight_decay 经常没效果"——因为它被自适应缩放吃掉了。

C40 ★★ 正则化手段有哪些？分别在防什么？

A：

手段	机制	备注
weight decay / L2	惩罚大权重	与 BN 一起时要注意耦合（AdamW 解耦）
Dropout	随机置零 + 推理时缩放（或训练时 inverted dropout）	CNN 里现在少用（BN 已正则），FC 层仍常用
DropPath / Stochastic Depth	随机"跳过整个残差块"	**深网络/ViT 标配**，比 Dropout 更适合残差结构
Label Smoothing	软标签	防过度自信、提升校准
Mixup / CutMix	混合样本与标签	强增广，小数据提点明显；**训练更慢、对检测/分割需适配**
早停	验证指标不涨就停	最朴素也最有效
数据增广	见 C11	最"正统"的正则（不改模型）

追问：Dropout 和 BN 一起用为什么有时会掉点？→ 两者都在做"噪声/尺度"层面的正则，叠加后训练/推理的方差估计不一致（Dropout 改变激活方差，BN 统计量随之变化），实践中常改为只用其一。

C41 ★★ 迁移学习怎么微调？冻结哪些层？

A：按"数据量 + 领域差异"四象限决策：

	数据少	**数据多**
领域相近	只训分类头（冻结 backbone）	解冻全部，小学习率微调
领域差异大	训部分深层 + 头（浅层通用特征保留）	全部解冻（甚至从头训）

关键细节（面试常问）： - **BN 层**：微调时常见做法是**冻结 BN 的统计量**（保持预训练的 running mean/var，只训 γ/β），尤其小 batch 时——否则统计量会被目标任务的小 batch 带偏。 - **分层学习率**：浅层小（如 1/10）、深层大。 - **先冻后解冻**：先只训头几轮（稳定），再解冻微调（避免早期大梯度破坏预训练特征）。

C42 ★★ 训练 loss 正常但验证指标不涨，和过拟合怎么区分？

A：看**两条曲线的组合**：

现象	判断	处理
train loss ↓、val loss ↓ 但指标不涨	**指标与损失口径不一致**（见 S9 Q115）	拆指标成分、检查解码/阈值
train loss ↓、val loss ↑	**过拟合**	加正则/增广、减容量、早停
train loss 不降	**欠拟合或优化问题**	加容量、查 lr/初始化/数据管线
train loss ↓、val loss 平稳且指标差	**分布差异**（train/val 不同源）	查数据划分与预处理一致性

最常见也最隐蔽的一条：训练和推理的预处理不一致（归一化参数不同、resize 插值不同、通道顺序不同）——这种 bug 会让"训练很好、验证很差"，且极难从 loss 曲线看出。

C43 ★ 梯度累积和分布式训练的注意点？

A：

- **梯度累积**：`loss/N` 累加 N 步再更新，模拟大 batch。**注意 BN 的统计量仍按真实 batch 算**（不等价于真的大 batch，除非换 SyncBN 或 GN）。
- **DDP（DistributedDataParallel）**：多进程、每卡一个模型副本，梯度 all-reduce 同步——**推荐**。
- **DP（DataParallel）**：单进程多线程，主卡瓶颈严重——**已不推荐**。
- **SyncBN**：跨卡统计 BN，使"多卡小 batch"等价于"单卡大 batch"（检测/分割必备）。

C44 ★ 训练不稳定/掉点，排查顺序？

A：和 S9 Q117 同源，但 CV 特有两条**放在最前面**：

1. **数据管线一致性**（最常翻车）：训练/验证的 resize、归一化、通道顺序、色彩空间（BGR vs RGB）是否一致；
2. **BN 的 train/eval 模式**（忘记 `model.eval()` 是最经典 bug）；
3. 之后才是：label 越界 → 数值溢出（fp16）→ 学习率/warmup → 初始化/结构 → 硬件/框架。

C5 图像任务的评价指标（C45–C50）

C45 ★★★ 分类/检测/分割的核心指标各是什么？给一张能背的表。

A：

任务	主指标	定义要点	常见陷阱
分类	top-1 / top-5 acc	预测概率最高的类别是否命中 / 前 5 是否命中	类别不平衡时看 **macro-F1** 而非 acc
	AUC	排序质量，与阈值无关	极不平衡时 AUC 会虚高
检测	**mAP**	各 IoU 阈值下的 AP 平均	口径差异极大（见 C46）
	AP50 / AP75	IoU=0.5 / 0.75 的 AP	单一阈值不够全面
分割	**mIoU**	各类 IoU 的平均	小目标被大类淹没；边界不计
	Dice / F1	`2TP/(2TP+FP+FN)`	与 IoU 单调相关但不相等
	Boundary IoU	只算边界附近像素	对边界质量更敏感
深度	EPE / δ<1.25^k / bad pixel	平均端点误差 / 相对误差阈值 / 超阈值比例	尺度对齐方式不同

C46 ★★★ mAP 的口径差异有多大？VOC 和 COCO 怎么区分？

A：mAP 是"最容易被口径坑"的指标：

	VOC（2007/2012）	COCO
IoU 阈值	**单一 0.5**	**0.5 : 0.05 : 0.95 共 10 个**，再平均
PR 曲线积分	2007 用 11 点插值；2012 起用全点插值	全点插值（101 点采样）
类别平均	所有类 AP 的均值	同，但另有 APs/APm/APl（按面积）与 AR（召回）

结论：**COCO AP 的数值通常比 VOC mAP@0.5 低 15~25 个点**，两者不能直接比较。面试报指标必须说清"哪个口径、哪张表"。

追问：AP 的"插值"是什么？→ PR 曲线是锯齿状的，用"右侧最大值包络"（`p_interp(r) = max_{r'⩾r} p(r')`）消除锯齿后再积分。

C47 ★★ mIoU 和 Dice 什么关系？为什么分割常报 mIoU 又报 Dice？

A：两者单调相关，有闭式关系：

```
Dice = 2·|A∩B| / (|A| + |B|) = 2·IoU / (1 + IoU)
```

关系：IoU 0.5 ↔ Dice 0.667；IoU 0.8 ↔ Dice 0.889。所以 Dice 永远比 IoU 大。

为什么都报：① 领域习惯（医学爱用 Dice，自动驾驶爱用 mIoU）；② 两者对小目标的敏感度不同（Dice 对小目标更"宽容"，因为分母不含 TN）；③ 比赛/论文的口径要求。

Boundary IoU 补什么：mIoU 对"整体面积对、边界糊"不敏感；Boundary IoU 只在边界带内计算 IoU，专门衡量**边界质量**（这对占用/分割的精细度量很关键）。

C48 ★★ 深度/立体匹配的评价指标？

A：

- **EPE（End-Point Error）**：预测与 GT 的平均欧氏距离（视差或深度空间），最常用。
- **δ < 1.25^k（k=1,2,3）**：`max(pred/gt, gt/pred) < 1.25^k` 的像素比例（相对误差阈值），越大越好，是单目深度的标准指标。
- **Bad pixel（bad 1.0/2.0/3.0）**：误差超过阈值（如 1px 视差、或相对 3%）的像素占比。
- **AbsRel / RMSE / log10**：相对误差、均方根误差、对数误差。

坑：单目深度要看是否做过**尺度对齐**（median scaling / 最小二乘对齐）——不做对齐的 AbsRel 没有可比性（见 B 部分 Q108 尺度歧义）。

C49 ★ 生成质量的 FID/IS/CLIPScore 各有什么局限？

A：

指标	衡量	局限
IS	生成图的类别可分性	只在 ImageNet 类别上有意义、可被"每类各生成一张"刷高
FID	生成分布与真实分布在 Inception 特征空间的距离	依赖 Inception 特征（对纹理敏感）；**小样本时估计有偏**；对"语义错误但纹理像"不敏感
CLIPScore	图文一致性（CLIP 相似度）	只测粗粒度对齐（不擅长计数/空间关系）
人工评估	最终裁判	贵、主观、需要一致性设计

面试话术："FID 只能说明'像不像那个分布'，不能说明'对不对'——所以生成任务我都会配一个人工抽检或任务级指标。"

C50 ★ 图像任务的损失怎么选？（与 S9 交叉）

A：一句话汇总（详细见 S9）：

- **分类**：CE + label smoothing（不平衡用 focal）；
- **框回归**：SmoothL1 + IoU 族（GIoU/DIoU/CIoU）；
- **分割**：CE（主）+ Dice/Lovasz（辅）；
- **深度/视差**：SmoothL1 on 有效区域（+ 尺度不变项、+ photometric）；
- **去噪/超分**：L1（比 L2 更锐）+ 感知损失（LPIPS/VGG 特征）+ GAN 损失；
- **风格化**：内容损失 + 风格损失（Gram 矩阵）。

C6 与传统流程、多模态的接口（C51–C54）

C51 ★★ 预处理细节对 VLM/下游的影响有多大?

A：影响极大，且是最常见的"训练/推理不一致"来源。四个必须对齐的点：

1. **归一化参数**：CLIP 系用 `mean=(0.4815,0.4578,0.4082)`、`std=(0.2686,0.2613,0.2758)`（OpenAI 的口径），用 ImageNet 的 mean/std 会**直接掉点**。
2. **resize 策略**：短边 resize + 中心裁剪（分类）vs 直接拉伸（会变形，OCR 类任务致命）vs 保持长宽比 + pad。
3. **通道/色彩**：OpenCV 默认 **BGR**、PIL 是 RGB——混用会让红蓝互换（模型仍能跑，但性能莫名下降）。
4. **插值方式**：双线性 vs 双三次 vs area，在缩小倍数大时差异明显。

面试话术："我会把预处理写成一个**唯一函数**被训练和推理共用，并加一条断言校验（形状、dtype、均值范围），避免两边各写一套。"

C52 ★★ 图像增广在 VLM 微调里为什么有风险?

A：因为**标签是自然语言**，增广会破坏"图文一致性"：

- 颜色抖动 → 图像从"红色苹果"变"橙色苹果"，但 caption 还说红色 → **制造假监督**；
- 裁剪 → 目标被裁掉，但回答还在描述它；
- 翻转 → 文字反了、左右关系错了（"左边的车"变"右边"）；
- Mixup → 语义变成"两个物体的叠加"，而文本没有这样的描述方式。

安全做法：只做**不改变语义**的增广（轻微的缩放/亮度/JPEG 压缩/小角度旋转），或者用**同步生成的修改后文本**（成本高）。这也是"VLM 的数据增广比 CV 保守得多"的原因。

C53 ★ 深度学习时代，传统图像处理还有用吗?

A：有用，而且在工业里**不可替代**。四个位置：

1. **预处理**：去畸变、白平衡、CLAHE、去噪（这些是几何/物理校正面，学习做不好也不该学）。
2. **几何校正**：标定、单应、极线校正（立体匹配必须先做）。
3. **后处理**：形态学去噪、连通域分析、轮廓拟合、NMS（很多是确定性算子，比神经网更可控）。
4. **数据生产**：标注工具、自动标注（用传统几何生成伪标签）、数据质量检查（模糊/过曝/重复检测）。

一句话："神经网络负责**语义理解**，传统方法负责**几何正确性和确定性约束**——两者的分工在工业落地里很清晰。"

C54 ★★ 一个完整工业视觉链路的典型顺序?

A：从传感器到输出的标准流程（面试画出来很加分）：

```
采集 → 时间同步/去畸变（标定）→ 色彩/亮度校正（CLAHE、白平衡、去噪）
     → 几何变换（resize / 切块 / 单应到 BEV）→ 归一化 → 网络推理
     → 后处理（解码、NMS、阈值、形态学）→ 跟踪/融合 → 业务规则
```

每一环都可能成为瓶颈：采集（曝光）、同步（时间戳）、校正（标定漂移）、预处理（CPU 耗时）、推理（prefill/decode）、后处理（NMS 在 CPU 上很慢）。

面试收尾："所以我判断一个 CV 系统的问题，习惯先看**链路哪一段的输入输出不对**，而不是直接怀疑模型——80% 的线上问题在模型外面。"

C7 视觉基础模型：DINO 家族与 DPT（C55–C68）

> 这一节补两个在面试里高频、但极容易被答混的东西：**DINO（有两个完全不同的算法同名）** 和 **DPT（ViT 做密集预测的经典改造）**。它们分别对应两条真实需求：**选视觉塔**（DINO/DINOv2）和 **做像素级输出**（DPT，深度/分割）。

C55 ★★★ DINO 有两个完全不同的算法，怎么区分？

A：这是面试的高频陷阱，**同名但毫无关系**：

	DINO（自监督）	**DINO（检测器）**
全称	**DI**stillation with **NO** labels	**D**ETR with **I**mproved de**NO**ising anchor boxes
出处	Meta / Inria，2021（Caron 等）	IDEA，2022（Zhang 等）
任务	**自监督预训练**（不需要标签，学表征）	**目标检测**（有监督，出框）
输出	视觉特征 / 注意力图	检测框 + 类别
关键词	teacher-student 自蒸馏、EMA、multi-crop、防坍塌	3D 可变形注意力、对比去噪、混合 query 选择
在 COCO 的地位	—	首个在 COCO 上刷到 63+ AP 的 DETR 系模型

答法："您说的 DINO 如果是视觉塔那个，是自监督的 DINO/DINOv2；如果是在检测榜单上那个，是 DETR 系的 DINO 检测器——两者只是缩写撞名了。"（**这一句能立刻分清你在哪一层**）

C56 ★★★ 自监督 DINO 怎么训练？为什么不会坍塌？

A：**自蒸馏（self-distillation）**：

```
同一张图做两个不同视角（crop/增广）→ student 看视角 A、teacher 看视角 B
teacher 的输出经过 centering + sharpening 后作为"软标签"
student 输出与之算交叉熵；teacher 的权重 = student 权重的 EMA（不参与梯度）
```

三个防坍塌的机制（必答）：

1. **EMA teacher**：teacher 更新慢（动量 0.99+），提供稳定的目标，避免 student 和自己同步跑偏。
2. **Centering**（减均值）：把 teacher 输出的均值减掉，**防止某一维主导**（否则所有样本都预测成同一个 one-hot）。
3. **Sharpening**（低温 softmax，$\tau \approx 0.04$）：让 teacher 分布变尖，**防止输出塌成均匀分布**。

关键理解：centering 和 sharpening 的作用**方向相反**（一个鼓励均匀、一个鼓励尖锐），两者**必须配对**——只做 centering 会塌成均匀，只做 sharpening 会塌成 one-hot。

与对比学习的区别：DINO **不需要负样本、不需要超大 batch**（SimCLR/MoCo 靠负样本防坍塌），这是它工程上更友好的原因。

C57 ★★ 多裁剪（multi-crop）策略起什么作用？

A：每张图取 **2 个 global crop（大视野，如 224）+ 若干个 local crop（小视野，如 96）**：

- **global crop 之间**互相比（学全局语义、物体级不变性）；
- **local crop 只和 global 比**（学局部到全局的对应，即"这块局部属于哪个整体"）。

收益：在不增加 batch 的情况下大幅增加"同一图像的视角数"，等价于廉价的强增广；而且逼模型学"局部—全局"关系（这也是 DINO 的 attention map 能自然对应物体区域的原因之一）。

追问：local crop 之间为什么不互相比？→ 两个小局部之间可能本来就不属于同一个物体（甚至没有重叠），强行对齐会引入错误监督。

C58 ★★★ DINOv2 相对 DINO 的关键改进？

A：五个层面：

层面	改进
数据	自建 **LVD-142M**（约 1.4 亿图文/图像）——用自监督检索 + 去重从公开数据里"挑"出与目标分布相似的子集（而不是直接堆量）
训练目标	自蒸馏 loss **+ 掩码图像建模（iBOT 式）** 双目标：前者学不变性，后者学局部细节
防坍塌	**Sinkhorn-Knopp centering**（替代简单减均值）+ **KoLeo 正则**（鼓励特征在空间里分散，防止挤成一团）
规模	从 ViT-S 一路到 **ViT-g（约 11 亿参数）**，且**蒸馏出小模型**（大模型当 teacher，小模型学）
使用方式	明确主打"**冻结特征直接可用**"：linear probe / k-NN 就接近微调效果

一句话："DINOv2 = DINO 的自蒸馏 + iBOT 的掩码建模 + 更大的精挑数据 + 更好的防坍塌与正则。"

C59 ★★ DINOv2 的特征和 CLIP 特征有什么本质差别?

A:

	CLIP	DINOv2
监督信号	**图文对**（语言监督）	**纯视觉自监督**（无语言）
特征倾向	**语义**（"这是什么"、可被语言描述）	**结构与实例**（形状、部件、同类区分）
优势任务	零样本分类、检索、图文对齐	分割、深度、对应、检测（**密集任务**）
弱点	细粒度空间与实例区分较弱	没有语言接口（不能做零样本文本查询）

为什么会这样：语言监督会把特征"压缩成语义类别"（猫的照片和猫的简笔画在 CLIP 空间接近）；而无语言监督必须靠**实例区分**（这只猫 vs 那只猫），所以保留了更多结构与个体信息。

面试加分："所以做 VLM 时，如果任务是'描述/问答'，用 CLIP 塔；如果要'精准定位/细粒度属性'，DINOv2 更合适；两者特征拼接（concat）也是常见做法——一个管语义、一个管结构。"

C60 ★★ 什么时候用 DINOv2 做视觉塔，什么时候用 CLIP?

A：决策表：

任务特征	选
图文检索、零样本分类、描述生成	**CLIP/SigLIP**（有语言对齐）
需要细粒度定位（grounding、OCR 边界、计数）	**DINOv2 打底**，或在 CLIP 塔上再加 DINOv2 分支
密集预测（分割/深度/占用）	**DINOv2**（结构信息丰富）
端侧/预算紧	CLIP 系成熟小模型（ViT-B）或蒸馏后的 DINOv2 小模型

坑（值得提）：DINOv2 的 patch 是 14，输入分辨率要求是 14 的倍数（如 224/336/518），不能随便 resize；而且它的特征维度（ViT-g 1536 维）比 CLIP 大，接 LLM 时投影层要更宽。

C61 ★★ 顺便问：DINO 检测器（同名那个）的四个关键技术?

A：简要四个（如果面试官问的是检测）：

1. **3D 可变形注意力**：参考点 + 采样偏移，只关注周围少量关键位置（比全局注意力省，且适合多尺度）。
2. **对比去噪（contrastive denoising）**：给 GT 加噪声生成正负 query（正：小噪声；负：大噪声），让模型学会"区分接近 GT 的框和干扰框"，加速收敛。
3. **混合 query 选择（mixed query selection）**：位置部分用 encoder 的 top-k 输出初始化，内容部分用可学习 query（因为 encoder 输出的内容信息不可靠）。
4. **look forward twice**：梯度回传时用上一层的梯度信息修正下一层的参数更新（"看两次"），提升精度。

一句话："DINO 检测器的三个关键词是**去噪、混合 query、两次前向**——它解决的是 DETR 收敛慢的问题。"

C62 ★★★ DPT 是什么？为什么 ViT 不能直接做密集预测？

A：**DPT（Dense Prediction Transformer）** 是把 ViT 改造成"能输出像素级结果"的经典架构（用于单目深度估计、语义分割）。

ViT 直接做不了密集预测的三个原因：1. **只有单一低分辨率**：patch 16 的 384 输入只有 24×24 个 token，输出的"特征图"太小，无法恢复边界；2. **没有多尺度特征**（不像 CNN 有 P3/P4/P5 的层级），而密集预测恰恰依赖多尺度；3. **没有 skip 连接**：UNet 的精度来自"深层语义 + 浅层细节"，ViT 缺这一半。

DPT 的解法：从 ViT 的**多个中间层**取 token → **reassemble** 成空间特征图 → **逐级上采样 + 卷积融合**（把深层的全局语义与浅层的细节结合）→ 输出全分辨率预测。

一句话："DPT 就是给 ViT 补上 CNN 的'金字塔 + skip'这两件事，同时保留 ViT 的全局感受野。"

C63 ★★★ DPT 的 reassemble 和 fusion 具体做了什么？

A：

Reassemble（把 token 变回图像）：

```
输入：某一层 ViT 的 (N+1, D) token（含 CLS）
步骤：① 丢掉 CLS，把剩余 N 个 token reshape 成 (D, H/p, W/p)
     ② read：把相邻 2×2 个 token 在通道维拼起来（类似 pixel shuffle），空间减半、通道 ×4
     ③ project：1×1 卷积把通道投到目标维度（如 256）
     ④ 再双线性上采样到 patches 分辨率的 4 倍（即 H/4）
```

Fusion（逐级融合，从深到浅）：

```
从最深的 reassemble 特征开始：
  上采样 2× → 与下一层的 reassemble 特征 concat → 两层 3×3 卷积（通道减半）
  重复到最高分辨率
最后：Refine 模块（stride 2 下采样再上采样，抑制上采样的棋盘/伪影）→ 1×1 conv 输出 1 通道深度
```

为什么 reassemble 要"2×2 拼通道"：ViT 的 token 之间是**无空间邻接信息**的（只是一维序列），把 2×2 邻居拼进通道，等于**显式地把空间邻接关系还原**，比单纯 reshape 更能保住局部结构。

追问：为什么要用多个中间层而不是只用最后一层？→ 最后一层语义最强但空间细节最弱；**中间层（如第 6、9、12 层）兼有细节与语义**，这正是"ViT 版的 FPN"。

C64 ★★ 为什么 DPT 的深度边界比 CNN 更锐利？

A：两个原因：

1. **全局注意力**：每个 token 都能"看到"整幅图，所以它能判断"这块区域和远处那块是同一个平面还是不同物体"，而 CNN 受局部感受野限制、容易在边界处模糊。
2. **多尺度融合时的高分辨率通路**：reassemble 保留了 patch 级的空间信息，配合逐级上采样，边界不会被过度平滑。

代价：ViT 的 token 少（384 输入只有 576 个），细节恢复依赖上采样卷积——所以在"极细的边界"（如铁丝网、远处小物体）上反而不如高分辨率 CNN；这也是后来 Depth Anything 等用**更大输入分辨率 + 更强数据**来补的原因。

C65 ★★★ DPT 的训练损失为什么必须"尺度/位移不变"？

A：因为**单目深度有尺度歧义**：同一张图，预测 2 米和 4 米可能只差一个全局缩放，而"形状结构"完全正确。如果用普通 L1，模型会把大量梯度花在"整体缩放"这个本就不确定的方向上。

DPT 用 **scale-and-shift-invariant loss**：

```
先对预测做最小二乘对齐：d* = a · d_pred + b
其中 a、b 由最小二乘闭式解得到（与 GT 对齐）
然后 L = (1/n) Σ |d* − d_gt|
```

这正好对应 B 部分 Q108 的 SSI（尺度不变损失）——两者是同一个思想：**先消除不确定的全局尺度，再比较结构**。

追问：什么时候不能用尺度不变损失？→ 下游需要**绝对度量**时（占用、可通行区域、测距）。此时要靠传感器（激光/双目）提供绝对尺度，或用少量带尺度标注的数据做校准。

C66 ★★ DPT vs UNet vs SegFormer 的 MLP 头，怎么选?

A:

方案	结构	优势	劣势
UNet	CNN 编码-解码 + skip	边界精细、成熟、数据效率高	全局上下文弱（要靠深层堆叠）
DPT	ViT 多层 + reassemble + 融合	全局一致性好、边界锐利	参数量大、需要大输入分辨率才发挥
SegFormer 头	多尺度特征统一 MLP + 融合（无卷积）	极轻量、快	精细边界略弱

选型口诀："数据少、要精细边界 → UNet；要全局一致性（大面积深度/平面）→ DPT；要端侧速度 → 轻量 MLP 头。"

C67 ★★ Depth Anything 和 DPT 是什么关系?

A：**Depth Anything 用 DPT 作为解码头**，核心创新在**数据与训练策略**，不在网络：

1. **数据规模化**：用 6200 万张无标注图像做自监督（教师模型生成伪深度，学生学），相当于把 DPT 放进"数据引擎"里；
2. **语义先验**：利用 DINOv2 初始化视觉编码器（**注意：DINOv2 + DPT 是当前单目深度的主流组合**）；
3. **强增广**：对无标注数据做强扰动（颜色、模糊），逼模型对扰动不变；
4. **V2 的改进**：合成数据 + 更大教师 + 分阶段训练，并解决了"深度图有幻觉细节"的问题。

面试话术："Depth Anything 的贡献不是结构，而是把 DPT 这类头放进了'大规模数据 + 强增广 + 教师蒸馏'的流水线——这正好说明在视觉任务里，**数据和训练策略的收益常常大于结构创新**。"

C68 ★ 如果面试官说"我们想用 DINO 做视觉塔"，你会怎么回应?

A：这是个开放题，分三步答（展示你能落地）：

1. **先确认是哪个 DINO**："您指的是自监督的 DINO/DINOv2，还是检测的 DINO？"
2. **如果确定是 DINOv2 做视觉塔**，指出两个必须解决的对接问题： - **没有语言对齐**：DINOv2 特征不能直接零样本查询，需要靠指令微调把语义"教"进去（或与 CLIP 特征融合）； - **分辨率约束**：patch 14，输入必须是 14 的倍数；token 数与分辨率挂钩，要注意预算。
3. **给出建议**："我倾向 DINOv2 做**密集任务**（定位/深度/占用）的特征源，语义问答类仍用 CLIP/SigLIP；如果两者都要，就双塔拼接后过投影层——代价是 token 数和显存翻倍。"

这道题的价值：它同时考"你分不分得清同名模型"、"你知不知道 DINOv2 的局限"、"你能不能给出取舍"。

附：复习优先级（A/B/C 三部分）

优先级	题目
必须能讲（A 部分 12 题）	A1 A2 A3 A7 A13 A14 A23 A24 A31 A32 A33 A39
必须能推（B 部分 14 题）	B2 B3 B9 B12 B13 B14 B17 B18 B20 B29 B30 B37 B38 B40
必须能分清/讲清（C 部分模型篇 6 题）	**C55**（两个 DINO 同名不同物）**C56**（自蒸馏为什么防坍塌）**C58**（DINOv2 改进）**C62**（ViT 为什么不能直接做密集预测）**C63**（DPT reassemble+fusion）**C65**（尺度不变损失）
必须能算（C 部分 10 题）	**C13**（输出尺寸）**C14**（感受野）**C15**（参数量/FLOPs）**C18**（BN/LN/GN）**C20**（残差梯度）**C29**（bottleneck 参数）**C38**（SGD vs Adam）**C45/C46**（指标口径）**C51**（预处理一致性）
能讲 1 分钟（A 其余）	A4–A6 A8–A12 A15–A22 A25–A30 A34–A38 A40–A45
能讲 1 分钟（B 其余）	B1 B4–B8 B10 B11 B15 B16 B19 B21–B28 B31–B36 B39 B41–B45
能讲 1 分钟（C 其余）	C1–C12 C16 C17 C19 C21–C28 C30–C37 C39–C44 C47–C50 C52–C54 C57 C59–C61 C64 C66–C68

现场最值钱的七个"能算"（面试官会让你当场推）

1. **卷积输出尺寸** `O = floor((I + 2P − K)/S) + 1`（C13）
2. **感受野递推** `RF_l = RF_{l−1} + (K_l−1)·Π S_i`，三个 3×3 = 一个 7×7 的感受野，但参数只有 55%（C14）
3. **参数量对比** 标准 3×3(256→256) = 589,824 vs 深度可分离 = 67,840（约 1/8.7）（C15）
4. **bottleneck 省算力** 589,824 → 69,632（约 1/8.5）（C29）
5. **softmax+CE 的梯度** `∂L/∂z = p − y`（B3）
6. **为什么除 √d_k** `Var[q·k] = d_k`（B38）
7. **残差为什么救梯度** `∂L/∂x_l = ∂L/∂x_L·(1 + ∂ΣF/∂x_l)`，那个 1 是恒等路径（C20）

B/C 两部分最容易被追问的三个"为什么"

- softmax 为什么减 max（B2）→ 上溢成 inf 再除得 nan，数学等价
- kmeans 为什么只是局部最优（B30）→ 非凸 + 坐标下降，附实测 20 个种子 7 次失败
- BN 为什么 CV 默认用（C18）→ 卷积核共享让通道统计量稳定，同时平滑损失曲面