华为多模态大模型岗 · 面试速查卡（面试前 10 分钟看这一张）

> **说明**：本文档为对外分享版，前雇主项目的量化指标已做量级化处理，方法论与话术保持原样。

开场 30 秒自述：我做过视觉+激光两种异构模态在统一 BEV 网格上的对齐融合，并负责过数据生产、指标归因、大规模训练稳定性、ONNX→ATC→MDC 端侧部署整条链路。多模态大模型我最有底气的是跨模态对齐、长序列建模、大规模训练调优和推理落地四块，VLM 的结构与 SFT/偏好对齐在系统补齐。

A. 必须脱口而出的 15 问（只看关键词）

问	一句话答案
ViT / token 数	patch 切块 + 线性投影 + 位置编码；224/16→196、384×704/16→1056、4K/patch14→42,196
视觉 token 太多	池化/Perceiver-Q-Former/token merge/pixel shuffle/剪枝；**我的 BEV query 就是几何约束下的 token 重组**
CLIP	双塔 + 对称 InfoNCE，batch 内 2(B−1) 个负样本；**大 batch 是命门**
LLaVA 为什么 MLP 够	冻结双塔下简单投影≈Q-Former；token 预算宽松选 MLP，紧就压 query
对齐三层	表征对齐 / 粒度(region)对齐 / 行为对齐(SFT+偏好)
VLM 三件套	视觉塔 + 桥接层 + LLM；细节是占位 token 与冻结策略
训练三阶段	对齐只训 projector → SFT 解冻 LLM（只对 assistant 算 loss）→ 偏好对齐
LoRA	ΔW=BA 低秩，只给 A/B 存梯度与优化器状态；rank 8~64、alpha≈2r；推理可合并零延迟
显存	参数 2P + 梯度 2P + 优化器 12P + 激活；ZeRO 1/2/3 + 检查点 + bf16
幻觉根因	**语言先验压过视觉证据**：数据噪声/自回归偏好流畅/视觉 token 弱/缺拒答样本
评测	MMBench(CircularEval) / MMMU(学科推理) / POPE(幻觉) / HallusionBench / RefCOCO(grounding) / VideoMME
POPE	random / popular / **adversarial**（只报随机负样本会虚高）
KV cache	2 · 层数 · kv头 · dhead · seq · batch · 字节；32层/32头/d128/2048 ≈ 1.07GB
Prefill vs Decode	前者计算密集（大 GEMM），后者访存密集（读权重+KV）
昇腾（送分）	CANN→ATC→AOE→AscendCL→ `.om`；算子不支持要拆/等价改写、精度对齐、动态 shape 分档

B. 手撕骨架（背这 6 行，代码现场翻译）

```
softmax : x -= max(keepdim) → e=exp(x) → e/e.sum(keepdim)
CE      : loss = logsumexp(logits) − logit[target]; 批量取 mean
LN      : γ·(x−μ)/√(σ²+ε)+β，μσ 沿最后一维，除 D
kmeans  : d=|x−c|²→argmin 分配→簇内均值→|Δc|<tol 停; 空簇保留旧中心; 多次初始化取 inertia 最小
MHA     : Q,K,V=XW → S=QKᵀ/√dk → mask(−1e9) → rowSoftmax → O=AV → concat 各头 ·Wo
CART    : Gini=1−Σp²; 枚举(特征,相邻中点)取加权 Gini 下降最大 → 左右递归; 叶取多数类
```

numpy 六个必会：`keepdims=True`（聚合后还要逐元素运算时必须加）、`axis=-1`、"axis=k 则该维消失"、`X[:,None,:]` 插轴做广播、`logits[np.arange(N),t]` 交叉索引、`argsort(-s)` 降序下标、`copy()`（赋值是引用）。

torch 六个坑：`max(...).values`、参数名 `dim/keepdim`、`masked_fill(True=屏蔽)`、`gather` 代替高级索引、`transpose` 后必须 `contiguous()` 才能 `view`、`F.scaled_dot_product_attention` 的 bool mask **语义相反（True=允许）**。

C. 力扣 C++ 骨架

```
// IO
ios::sync_with_stdio(false); cin.tie(nullptr);
// 快排: 随机 pivot → swap 到 l → 分区 → 递归
// 二分: lo=0, hi=n 左闭右开; mid=lo+(hi-lo)/2
// 滑窗: last[128]=-1; if(last[c]>=left) left=last[c]+1
// TopK: priority_queue<int,vector<int>,greater<int>>
// DSU: find 路径压缩 + 按秩合并
// 01 背包: 内层倒序（正序会退化成完全背包）
```

易错：`long long` 溢出；`size()-1` 无符号下溢；`sort` 比较函数必须严格弱序；`unordered_map[]` 会插入默认值；`cin>>` 后接 `getline` 要 `ignore()`。

D. 三句最高分话术

1. **融合 ↔ cross-attention**："我的融合是静态门控，改造会换成 query-based cross-attention：**BEV query 作 Q、图像特征作 K/V**，让权重按位置和内容动态生成——这正是 BEVFormer 与 Q-Former 的共同思路。"
2. **BEV query vs Q-Former**："形式上同类，差别在**几何先验**：BEV query 对应固定世界坐标格子、靠内外参投影，位置物理正确；Q-Former 的 query 无几何约束。前者适合度量精度，后者适合语义检索。"
3. **端侧三问**："我会先问目标 SoC 的**算子白名单、内存预算、是否允许动态分辨率**——我在 MDC610 上做过 ONNX→ATC/AOE→ `.om` 全链路，对不支持算子做过解耦+等价改写。"

E. 不会的题（三步法）

① **缩范围**："您问的是训练侧还是推理侧？" ② **给相邻知识**："这块我没在生产做过，但相邻问题是这样解决的……" ③ **给验证路径**："让我做的话会先用 XX 指标做小规模对照，再放大。" **面试官容忍"不会"，不容忍"编"。**

F. 七条红线

① 不报参数量（百万级参数量 会被打穿）② 不说训过 LLM/VLM ③ 不说论文已发表 ④ 不说做过 SLAM ⑤ 不跨协议比指标（先口径后数字）⑥ 不把"读过"说成"复现过" ⑦ 不确定的数字给量级。

G. 反问三连

① 多模态主要在哪个模态组合上做，瓶颈在数据、结构还是推理成本？② 端侧与云侧比例、时延算力预算，昇腾侧是自研 ATC 还是 MindSpore 栈？③ 新人前三个月最可能被派到哪块（数据/训练/评测/部署）？

H. 交付清单

```
桌面/
├ 华为多模态大模型-面试手册-完整合并版.pdf
106 页（封面+5 份，415 书签）
├ 华为-多模态大模型-面试速成指南_20261029.pdf
10 页
├ 华为-多模态大模型-八股知识问答_20261029.pdf
25 页（118 问，含融合调控+损失）
├ 华为-多模态大模型-VLM与ML算法八股_20261029.pdf
39 页（144 问 + B6 验算代码 47 项断言）
├ 华为-多模态-手撕AI题详解_C++版_20261029.pdf
18 页（力扣 C++）
├ 华为-多模态-手撕AI题详解_Python版_20261029.pdf
15 页（AI 题 Python）
├ 华为-多模态大模型-面试速查卡_20261029.pdf
2 页（本卡）
├ ai_interview_cpp_手撕题库已验证_20261029.cpp
26 项断言
└ ai_interview_py_手撕题库已验证_20261029.py
39 项断言（含 torch 对拍）
```